

# Proyecto 3

## Econometría Aplicada y Ciencia de Datos

### Instrucciones

**Fecha de entrega:** 30 de octubre (hasta 23h59) por email (cgbrito@ucdavis.edu) Pueden escribir la tarea en L<sup>A</sup>T<sub>E</sub>X o Word, o entregarla escrita a mano (escaneada o fotografiada de forma legible).

### (1) Descomposición de Bacon

Considere un panel con tres grupos:  $k$  (tratados temprano, en  $t = 2$ ),  $l$  (tratados tarde, en  $t = 4$ ) y  $U$  (nunca tratados), observados en 5 periodos ( $t = 1, \dots, 5$ ). Como en el ejemplo visto en clase,  $k$  pasa el 80 % del tiempo tratado ( $\bar{D}_k = 0,8$ ) y  $l$  pasa el 40 % del tiempo tratado ( $\bar{D}_l = 0,4$ ). Los tamaños de los grupos son  $n_k = 20$ ,  $n_l = 30$  y  $n_U = 50$ .

- (a) Describa, en palabras y usando la notación PRE/MID/POST vista en clase, los tres tipos de comparaciones  $2 \times 2$  que TWFE realiza implícitamente entre  $k$ ,  $l$  y  $U$ . ¿Cuál de estas comparaciones se considera “prohibida” (*forbidden*) y por qué genera un problema distinto al de tendencias paralelas?
- (b) Recuerde las fórmulas de los pesos de Goodman-Bacon:

$$s_{kU} = \frac{n_k n_U \bar{D}_k (1 - \bar{D}_k)}{\widehat{\text{Var}}(\tilde{D}_{it})}, \quad s_{kl} = \frac{n_k n_l (\bar{D}_k - \bar{D}_l) (1 - (\bar{D}_k - \bar{D}_l))}{\widehat{\text{Var}}(\tilde{D}_{it})}, \quad \mu_{kl} = \frac{1 - \bar{D}_k}{1 - (\bar{D}_k - \bar{D}_l)}.$$

Como  $\widehat{\text{Var}}(\tilde{D}_{it})$  es común a todas las comparaciones, basta con calcular los *numeradores* de  $s_{kU}$ ,  $s_{lU}$  y  $s_{kl}$  para obtener los pesos *relativos*. Calcule estos tres numeradores con los datos dados, normalícelos para que sumen 1, y calcule también  $\mu_{kl}$ .

- (c) Usando el resultado en (b), calcule qué proporción del peso total recae sobre la comparación *late-to-early* ( $l$  vs.  $k$ , es decir  $(1 - \mu_{kl}) \cdot s_{kl}$  normalizado). Comente si le parece una proporción despreciable o sustancial.
- (d) Suponga que el efecto del tratamiento para el grupo  $k$  *crece* en el tiempo (heterogeneidad dentro de grupo, como en el panel derecho del ejemplo gráfico visto en clase). Usando la descomposición

$$\hat{\delta}^{DD} = VWATT + VWCT - \Delta,$$

explique de dónde proviene el sesgo en este escenario, qué término de la ecuación lo captura, y por qué el peso calculado en (c) es relevante para el tamaño de ese sesgo.

- (e) Nombre un estimador alternativo a TWFE que evite explícitamente comparaciones *late-to-early*, y explique en una o dos oraciones cómo lo logra.

## (2) DiD con múltiples periodos

Un investigador estudia el efecto de la expansión de Medicaid sobre la mortalidad a nivel condado en EUA. Cuatro grupos de condados expandieron Medicaid en 2014, 2015, 2016 y 2019, respectivamente; otro grupo de condados nunca expandió Medicaid en la ventana muestral (2009–2019).

- Defina formalmente  $ATT(g, t)$  para este contexto (adopción escalonada), usando resultados potenciales  $Y_{i,t}(g)$  y  $Y_{i,t}(\infty)$ . Interprete en palabras qué mide  $ATT(2015, 2017)$ .
- Compare los tres supuestos de tendencias paralelas vistos en clase: PT-GT-Nev, PT-GT-NYT y PT-GT-all. Para cada uno, indique (i) qué grupo(s) de comparación permite usar, y (ii) qué periodo(s) base permite usar. Discuta el *trade-off* entre precisión estadística y fortaleza del supuesto al pasar de PT-GT-Nev a PT-GT-all.
- El investigador quiere estimar específicamente  $ATT(2015, 2017)$  (el efecto en 2017 para el grupo tratado en 2015). Para cada uno de los tres supuestos del inciso (b), indique explícitamente qué condados podrían usarse como grupo de control y qué año(s) podrían usarse como periodo base para ese caso concreto.
- Los  $ATT(g, t)$  estimados se agregan comúnmente en un parámetro de tiempo-evento:

$$ATT_{es}(e) = \sum_{g < \infty} w_{\omega, g, e}^{es} ATT(g, g + e).$$

Explique qué representa  $e$ , qué mide  $w_{\omega, g, e}^{es}$ , y describa (con un ejemplo usando los años 2014, 2015, 2016 y 2019 de este caso) qué estimadores  $ATT(g, t)$  específicos se promediarían para obtener  $ATT_{es}(0)$  y  $ATT_{es}(1)$ .

- Explique la diferencia principal entre el estimador de Callaway & Sant’Anna (2021) y el de Sun & Abraham (2021) en cuanto al grupo de control permitido. Enuncie la relación de equivalencia entre  $\beta_{g,e}^{SA}$  (de la regresión de Sun & Abraham) y  $\widehat{ATT}_{\text{never}}(g, t)$ .

## (3) Instrumentos shift-share

Un investigador quiere estimar el efecto de la expansión de banda ancha (*broadband*) sobre el crecimiento del empleo regional. Propone el instrumento

$$z_i = \sum_{k=1}^K s_{ik} g_k,$$

donde  $s_{ik}$  es el share del empleo de la región  $i$  en la industria  $k$  en el año **2005**, y  $g_k$  es una medida, a nivel **nacional**, de qué tan “intensiva en internet” es la industria  $k$  (es decir, qué tanto se beneficiaría típicamente una industria como  $k$  de una mejora en conectividad, calculada usando datos de otros países y no de las regiones de EUA en la muestra).

- Explique en sus propias palabras las dos fuentes posibles de identificación en un instrumento shift-share ( $z_i = \sum_k s_{ik} g_k$ ): identificación por shifts exógenos e identificación por shares exógenos.
- Para el instrumento propuesto arriba, ¿le parece más natural justificarlo por la vía de shifts exógenos o por la vía de shares exógenos? Justifique su respuesta usando las características de  $g_k$  descritas en el enunciado.

- (c) Usando el marco del “experimento ideal” (la lotería hipotética vista en clase con los subsidios de Bartik), describa el experimento ideal que justificaría la identificación por shifts exógenos en este caso. ¿Qué variable no observada generaría sesgo en MCO, y cómo la resolvería ese experimento ideal?
- (d) Explique por qué el investigador usa los shares de empleo de **2005** (y no los de, por ejemplo, 2015) para construir  $z_i$ . ¿Qué problema evita al rezagar los shares, y qué costo tiene rezagarlos demasiado?
- (e) De la lista de verificación (*checklist*) para el enfoque de shifts exógenos vista en clase, elija **dos** puntos (distintos al de rezagar los shares) y explique, aplicándolos a este ejemplo, qué problema de identificación o de inferencia atiende cada uno.