

ATT = Average treatment effect on the treated

ATE = Average treatment effect (whole population)

## Descomposición de Bacon

Econometría Aplicada y Ciencia de Datos - CIDE Fall 2026

$$ATT = ATE : RCT^1$$

Carlos Brito

LATE = local ATE: for the compliers of the IV

---

<sup>0</sup>El material de esta presentación se basa en el siguiente material: Cunningham, S. (2021). *Causal inference: The mixtape*. Yale University Press.

# Two-way fixed effects (TWFE)

Grupo  $g$  x Después  $t$

- En diff-in-diff, queremos controlar por diferencias por grupo, y diferencias por tiempo:

$$Y = \alpha_g + \alpha_t + \beta_1 \text{Tratado} + \epsilon$$

- $\alpha_g$  es efecto fijo de grupo,  $\alpha_t$  es efecto fijo de tiempo.
- La regresión de DiD es *two-way fixed effects* porque tenemos dos conjuntos de efectos fijos.
- Tratado* es una dummy = 1 si el individuo está siendo tratado. I.e.: si está en un grupo de tratamiento en el periodo después que el tratamiento toma efecto.
- $\beta_1$  es el estimador de diferencias en diferencias.
- Notar que en esta regresión puede haber muchos grupos que son tratados.

# Descomposición de Bacon

- Mensaje principal de la descomposición de Bacon:
  - El estimador de “two way fixed effects” (TWFE) es un promedio ponderado de todos los estimadores de DiD 2x2 potenciales.
- Donde el estimador 2x2 es:

$$\hat{\delta}_{kU}^{2 \times 2} = \left( \bar{y}_k^{\text{post}(k)} - \bar{y}_k^{\text{pre}(k)} \right) - \left( \bar{y}_U^{\text{post}(k)} - \bar{y}_U^{\text{pre}(k)} \right)$$

- $k$  es el grupo tratado y  $U$  el no tratado.
- Si los efectos del tratamiento no varían en el tiempo, entonces el estimador TWFE es un ATT.
- Sin embargo, **si los efectos del tratamiento varían en el tiempo en un diseño con tratamiento escalonado**, el estimador de TWFE puede generar sesgo.

# Ejemplo

1 2 3 4 5

1 2 3 4 5

- Hay tres grupos: los tratados primero ( $k$ ), los tratados después ( $l$ ) y los nunca tratados ( $U$ ).
- Hay 5 periodos:  $k$  es tratado en el 2 (pasa 80% del tiempo tratado,  $\bar{D}_k = 0.8$ ); ( $l$ ) es tratado en el 4 (40% del tiempo tratado,  $\bar{D}_l = 0.4$ ).
- La duración de tiempo que un grupo permanece tratado determina el peso que su estimación 2x2 juega en el parámetro de DiD final.
- Representemos cada 2x2 como  $\hat{\delta}_{a,b}^j$  donde  $a$  y  $b$  son grupos de tratamiento, y  $j$  es el índice del grupo en cuestión.
  - El 2x2 del grupo  $k$  comparado al  $U$  es  $\hat{\delta}_{kU}^k$ .

# Ejemplo



En nuestro ejemplo,  $k$  y  $l$  son tratados en  $t_k^*$  y  $t_l^*$ . "Pre" es el periodo antes de que cualquiera sea tratado. "mid" es el periodo después de tratar a  $k$  y antes de  $l$ . "post" es el periodo después de tratar a  $l$ .

A. Early Group vs. Untreated Group  $\hat{\delta}_{KU}^{2 \times 2}$

Comparación de  $k$  (tratado en  $t_k^*$ ) contra  $U$  (nunca tratado), en periodos PRE(k) y POST(k) 1 2 3 4 5

C. Early Group vs. Late Group, before  $t_l^*$   $\hat{\delta}_{Kl}^{2 \times 2}$

Comparación de  $k$  contra  $l$  en PRE(k) y MID(k, l).



B. Late Group vs. Untreated Group  $\hat{\delta}_{LU}^{2 \times 2}$

Comparación de  $l$  (tratado en  $t_l^*$ ) contra  $U$ , en periodos PRE(l) y POST(l).

D. Late Group vs. Early Group, after  $t_k^*$   $\hat{\delta}_{LK}^{2 \times 2}$

Comparación de  $l$  contra  $k$  en MID(k, l) y POST(l).



- Podemos resumir todos los estimadores de 2x2:

$$\hat{\delta}_{kU}^{2 \times 2} = \left( \bar{y}_k^{\text{post}(k)} - \bar{y}_k^{\text{pre}(k)} \right) - \left( \bar{y}_U^{\text{post}(k)} - \bar{y}_U^{\text{pre}(k)} \right), (k \text{ o } I)$$

$$\hat{\delta}_{kl}^{2 \times 2, k} \equiv \hat{\delta}_{kl}^{2 \times 2} = \left( \bar{y}_k^{\text{mid}(k, I)} - \bar{y}_k^{\text{pre}(k)} \right) - \left( \bar{y}_I^{\text{mid}(k, I)} - \bar{y}_I^{\text{pre}(k)} \right)$$

$$\hat{\delta}_{kl}^{2 \times 2, I} \equiv \hat{\delta}_{lk}^{2 \times 2} = \left( \bar{y}_I^{\text{post}(I)} - \bar{y}_I^{\text{mid}(k, I)} \right) - \left( \bar{y}_k^{\text{post}(I)} - \bar{y}_k^{\text{mid}(k, I)} \right)$$

- El primer 2x2 es cualquier tratado comparado con el no tratado ( $k$  o  $I$ ).
- El segundo 2x2 es un grupo ya tratado comparado con un grupo por tratar.
- El tercer 2x2 es un grupo aún no tratado comparado con un grupo ya tratado.

# Descomposición del estimador de DiD

- Goodman-Bacon (2021) muestra que el estimador de DiD se puede descomponer como sigue:

$$\hat{\delta}^{DD} = \sum_{k \neq U} s_{kU} \hat{\delta}_{kU}^{2 \times 2} + \sum_{k \neq U} \sum_{l > k} s_{kl} \left[ \mu_{kl} \hat{\delta}_{kl}^{2 \times 2, k} + (1 - \mu_{kl}) \hat{\delta}_{kl}^{2 \times 2, l} \right]$$

- donde  $\hat{\delta}_{kU}^{2 \times 2}$  incluye a  $l$  y a  $k$  para simplificar de la notación, y los pesos son:

$$s_{kU} + s_{lU} + s_{kl} = 1$$

$$s_{kU} \hat{\delta}_{kU}^{2 \times 2} + s_{lU} \hat{\delta}_{lU}^{2 \times 2}$$

$$s_{kU} = \frac{n_k n_U \bar{D}_k (1 - \bar{D}_k)}{\widehat{\text{Var}}(\tilde{D}_{it})}$$

$$s_{kl} = \frac{n_k n_l (\bar{D}_k - \bar{D}_l) (1 - (\bar{D}_k - \bar{D}_l))}{\widehat{\text{Var}}(\tilde{D}_{it})}$$

$$\mu_{kl} = \frac{1 - \bar{D}_k}{1 - (\bar{D}_k - \bar{D}_l)}$$

- $n$  es el tamaño de los grupos.
- $\widehat{\text{Var}}(\tilde{D}_{it})$  es la varianza del tratamiento después de eliminar los efectos fijos de unidad y de tiempo:
- En nuestro ejemplo:  $\bar{D}_k = 0.8$ ,  $\bar{D}_l = 0.4$

# Descomposición del estimador de DiD

- Aspectos importantes a notar en la ecuación:
- ① Es importante la variación grupal respecto al tiempo que se permanece tratado.
- ② Entre más grande sea un grupo de tratamiento dado, más influirá éste mismo en el estimador de DiD.
- I.e. el estimador DiD de TWFE es una suma de todos los posibles DiDs 2x2 pesados por el tamaño del grupo y la variación en la duración del tratamiento.

# Usando notación de resultados potenciales

- Para cada unidad  $i$  en el periodo  $t$  definimos dos **resultados potenciales**:
  - $Y_{it}^1$ : resultado que tendría  $i$  en  $t$  *si* estuviera tratada.
  - $Y_{it}^0$ : resultado que tendría  $i$  en  $t$  *si no* estuviera tratada.
- El **efecto causal** del tratamiento para  $i$  en  $t$  es  $Y_{it}^1 - Y_{it}^0$ .
- **Problema fundamental de la inferencia causal**: nunca observamos ambos, solo observamos

$$Y_{it} = D_{it} Y_{it}^1 + (1 - D_{it}) Y_{it}^0,$$

donde  $D_{it} = 1$  si  $i$  está tratada en  $t$ , y  $D_{it} = 0$  si no.

- Agrupamos a las unidades tratadas en el mismo periodo en un **grupo**  $k$ : todas las unidades tratadas por primera vez en el periodo  $k$ .
- El efecto promedio del tratamiento sobre el grupo  $k$ :

$$ATT_k = E [Y_{it}^1 - Y_{it}^0 \mid k]$$

# Usando notación de resultados potenciales

- Definamos un ATT específico a un año como:

$$ATT_k(\tau) = E [Y_{it}^1 - Y_{it}^0 \mid k, t = \tau]$$

- Lo definimos ahora respecto a una ventana de tiempo:

$$ATT_k(\tau) = E [Y_{it}^1 - Y_{it}^0 \mid k, \tau \in W]$$

- La diferencia en resultados potenciales en un periodo de tiempo es:

$$\Delta Y_k^h(W_1, W_0) = E [Y_{it}^h \mid k, W_1] - E [Y_{it}^h \mid k, W_0]$$

- Para  $h = 0$  (i.e.  $Y^0$ ) o Para  $h = 1$  (i.e.  $Y^1$ )

# Estimador 2x2 con resultados potenciales

- Ahora definamos el estimador DiD 2x2 en resultados potenciales

$$\begin{aligned}\hat{\delta}_{kU}^{2 \times 2} &= \left( E[Y_k | \text{Post}] - E[Y_k | \text{Pre}] \right) - \left( E[Y_u | \text{Post}] - E[Y_u | \text{Pre}] \right) \\ &= \left( E[Y_k^1 | \text{Post}] - E[Y_k^0 | \text{Pre}] \right) - \left( E[Y_u^0 | \text{Post}] - E[Y_u^0 | \text{Pre}] \right) \\ &\quad + \underbrace{E[Y_k^0 | \text{Post}] - E[Y_k^0 | \text{Post}]}_{\text{Adding zero}} \\ &= \underbrace{E[Y_k^1 | \text{Post}] - E[Y_k^0 | \text{Post}]}_{ATT_k} \\ &\quad + \underbrace{\left[ E[Y_k^0 | \text{Post}] - E[Y_k^0 | \text{Pre}] \right] - \left[ E[Y_u^0 | \text{Post}] - E[Y_u^0 | \text{Pre}] \right]}_{\text{Non-parallel trends bias in } 2 \times 2 \text{ case}}\end{aligned}$$

With parallel trends:  $= 0 \rightarrow \hat{\delta}_{kU}^{2 \times 2} = ATT_k$

# Estimador 2x2 con resultados potenciales

- O podemos re-escribir como:

$$\hat{\delta}_{kU}^{2 \times 2} = ATT_{\text{Post},j} + \underbrace{\Delta Y_{\text{Post,Pre},j}^0 - \Delta Y_{\text{Post,Pre},U}^0}_{\text{Selection bias!}}$$

- Así, el DiD 2x2 es la suma del ATT más un supuesto de tendencias paralelas.
- Sin tendencias paralelas, el estimador 2x2 está sesgado.

# Resultados potenciales para los estimadores 2x2 relevantes

- Usemos resultados potenciales para los estimadores 2x2 en un caso de tratados temprano ( $k$ ), tratados tarde ( $l$ ) y no tratados ( $U$ ).

**A, B:**  $\hat{\delta}_{kU}^{2 \times 2} = ATT_k \text{Post} + \underbrace{\Delta Y_k^0(\text{Post}(k), \text{Pre}(k)) - \Delta Y_U^0(\text{Post}(k), \text{Pre})}_{=0 \text{ under parallel trends}}$

**C:**  $\hat{\delta}_{kl}^{2 \times 2} = ATT_k(\text{MID}) + \underbrace{\Delta Y_k^0(\text{MID}, \text{Pre}) - \Delta Y_l^0(\text{MID}, \text{Pre})}_{=0 \text{ under parallel trends}}$

- El primer 2x2 incluye a los  $k$  y a los  $l$ .
- El segundo 2x2 es similar al primero porque también compara a tratados con no tratados (aunque en el segundo son “aún no tratados”).

## Aún no tratados vs. ya tratados (late to early)

- Veamos ahora el tercer 2x2.


$$\hat{\delta}_{lk}^{2 \times 2} = ATT_{l, \text{Post}(l)}$$

$$+ \underbrace{\Delta Y_l^0(\text{Post}(l), \text{MID}) - \Delta Y_k^0(\text{Post}(l), \text{MID})}_{\text{Parallel-trends bias}}$$

$$- \underbrace{(ATT_k(\text{Post}) - ATT_k(\text{Mid}))}_{\text{Heterogeneity in time bias!}}$$

- Como en los casos anteriores tenemos un sesgo dado por tendencias.
  - Si las tendencias en  $Y^0$  para  $k$  y  $l$  son paralelas entre el periodo *mid* y *post*, se elimina ese sesgo.
- También existe un sesgo dado por el efecto del tratamiento.
  - Ese sesgo se elimina si los efectos de tratamiento por grupo son constantes en el tiempo. :

$$ATT_k(\text{Post}) = ATT_k(\text{Mid})$$



## Aún no tratados vs. ya tratados (late to early)

$$\hat{\delta}^{DD} = \sum_{k \neq U} s_{kU} \hat{\delta}_{kU}^{2 \times 2} + \sum_{k \neq U} \sum_{l > k} s_{kl} \left[ \mu_{kl} \hat{\delta}_{kl}^{2 \times 2, k} + (1 - \mu_{kl}) \hat{\delta}_{kl}^{2 \times 2, l} \right]$$

- Así, **con tratamiento escalonado, inevitablemente se usarán grupos ya tratados como control de grupos** por ser tratados.
  - I.e., *late to early* 2x2.
- Siempre que los *late to early* 2x2 tengan un peso sustancial en el estimador global, la existencia de efectos del tratamiento heterogéneos, **sesga el parámetro DiD**.

- Sustituyendo los estimadores 2x2 con resultados potenciales en:

$$\hat{\delta}^{DD} = \sum_{k \neq U} s_{kU} \hat{\delta}_{kU}^{2 \times 2} + \sum_{k \neq U} \sum_{l > k} s_{kl} \left[ \mu_{kl} \hat{\delta}_{kl}^{2 \times 2, k} + (1 - \mu_{kl}) \hat{\delta}_{kl}^{2 \times 2, l} \right]$$

- se obtiene:

$$\text{plim } \hat{\delta}_{n \rightarrow \infty}^{DD} = VWATT + VWCT - \Delta ATT$$

- Revisemos cada componente de la ecuación.

## Variance weighted ATT (VW ATT)

$$\begin{aligned} VWATT = & \sum_{k \neq U} \sigma_{kU} ATT_k(\text{Post}(k)) \\ & + \sum_{k \neq U} \sum_{l > k} \sigma_{kl} [\mu_{kl} ATT_k(\text{Mid}) + (1 - \mu_{kl}) ATT_l(\text{POST}(l))] \end{aligned}$$

- donde  $\sigma$  son pesos que dependen de la duración del tratamiento.
- El VWATT es la suma de los tres ATTs definidos anteriormente.
- I.e., una parte del estimador DiD es un promedio ponderado de los ATTs grupales.

## Variance weighted common trends (VW CT)

$$\begin{aligned} VWCT = & \sum_{k \neq U} \sigma_{kU} [\Delta Y_k^0(\text{Post}(k), \text{Pre}) - \Delta Y_U^0(\text{Post}(k), \text{Pre})] \\ & + \sum_{k \neq U} \sum_{l > k} \sigma_{kl} \left[ \mu_{kl} \{ \Delta Y_k^0(\text{Mid}, \text{Pre}(k)) - \Delta Y_l^0(\text{Mid}, \text{Pre}(k)) \} \right. \\ & \left. + (1 - \mu_{kl}) \{ \Delta Y_l^0(\text{Post}(l), \text{Mid}) - \Delta Y_k^0(\text{Post}(l), \text{Mid}) \} \right] \end{aligned}$$

- Contiene todos los sesgos de tendencias no paralelas de los tres 2x2s, pesados con los mismos pesos utilizados en el VWATT.
- Para que el estimador DiD sea el ATT, es necesario tener tendencias paralelas (que el VWCT sea cero).
- Nótese, que no se necesita que las tendencias sean completamente paralelas, es suficiente que sean paralelas una vez pesadas con las varianzas del tratamiento.


# Heterogeneidad del tratamiento en el tiempo

$$\Delta ATT = \sum_{k \neq U} \sum_{l > k} (1 - \mu_{kl}) \left[ ATT_k(\text{Post}(l)) - ATT_k(\text{Mid}) \right]$$

- El sesgo por heterogeneidad del tratamiento en el tiempo se da si hay heterogeneidad *dentro* del grupo a través del tiempo.
- La heterogeneidad *a través* de grupos se captura por el VWATT y no causa sesgo.

# Heterogeneidad del tratamiento en el tiempo: ejemplo gráfico


Sin heterogeneidad dentro del grupo



El efecto es constante tras el tratamiento:

$$ATT_k(\text{Post}(I)) \text{ no depende de } I.$$

Con heterogeneidad dentro del grupo



El efecto *crece* con el tiempo desde el tratamiento:

$$ATT_k(\text{Post}(I)) \neq ATT_k(\text{Post}(I')) \text{ para } I \neq I'.$$

Esta variación *dentro* del grupo  $k$  (panel derecho) es la fuente del sesgo  $\Delta ATT$ : comparar el mismo grupo en distintos períodos "Post" ( $I$  vs.  $I'$ ) da estimaciones distintas del mismo efecto de tratamiento. En el panel izquierdo, en cambio, no hay sesgo porque  $ATT_k$  es el mismo para cualquier  $I$ .

# Descomposición de Bacon - lecciones

- La descomposición de Bacon demostró factores importantes que antes solo se avistaban metafóricamente al usar TWFE con tratamiento escalonado.
- ❶ El tamaño del grupo es importante para determinar el tamaño del estimador a través de los grupos (intuitivo).
- ❷ La variación del tratamiento a través del tiempo sesga el estimador (no necesariamente intuitivo).
- ¿Qué soluciones se pueden dar a este problema?

- Stevenson, B., Wolfers, J. (2006). Bargaining in the shadow of the law: Divorce laws and family distress. *The Quarterly journal of economics*, 121(1), 267-288.
- Sección 4 de Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254-277.
- Cheng, C., Hoekstra, M. (2013). Does strengthening self-defense law deter crime or escalate violence?: Evidence from expansions to castle doctrine. *Journal of Human Resources*, 48(3), 821-854.
- Secciones 9.6.6, 9.6.7 y 9.6.8 del libro Cunningham, S. (2021). *Causal inference: The mixtape*. Yale university press, <https://mixtape.scunning.com/>

# Solución - Callaway & Sant'Anna (2021)

- Callaway & Sant'Anna (2021)<sup>1</sup> proponen estimar el “group time average treatment effect”.
  - I.e., el ATT para un grupo dado en todo periodo de tiempo.
- Se calcula un ATT por tiempo asumiendo tendencias paralelas condicionales a ciertas variables de control y a un puntaje de propensión.
- Es estimador es no paramétrico, no utiliza una regresión.

---

<sup>1</sup>Callaway, B., & Sant'Anna, P. H. (2021). Difference-in-differences with multiple time periods. *Journal of econometrics*, 225(2), 200-230.

- El estimador grupal de ATT por tiempo es:

$$ATT(g, t) = E \left[ \left( \frac{G_g}{E[G_g]} - \frac{\frac{p_g(X)C}{1 - p_g(X)}}{E \left[ \frac{p_g(X)C}{1 - p_g(X)} \right]} \right) (Y_t - Y_{g-1}) \right]$$

- donde los pesos  $p$  son puntajes de propensión.
- $G = 1$  si un individuo es tratado por primera vez en el periodo  $g$ .  $C = 1$  si un individuo nunca es tratado.
- Así, se comparan individuos del grupo de control con el grupo  $g$ , y se omiten todos los demás.
- Además, se da más peso a los individuos del control que se parecen a los individuos del grupo  $g$ .

- Una vez que se calcula un ATT por grupo y tiempo, se toman promedios ponderados para obtener ATTs grupales (i.e., por cohort) para todo tiempo.
- Luego, se puede obtener un ATT global a través de todos los cohorts.
- Al usar las unidades nunca tratadas como control, el estimador no está sujeto al sesgo que resulta de comparar a los “late to early”.