

clustered robust :

$$\hat{V}_R(\hat{\beta}_{OLS}) = (X'X)^{-1} \left(\sum_{g=1}^G X_g' \hat{u}_g \hat{u}_g' X_g \right) (X'X)^{-1}$$

Asymptotic theory : $G \rightarrow \infty$

Bootstrap

Econometría Aplicada y Ciencia de Datos - CIDE Fall 2026

Carlos Brito

Standard Error

→ Moulton factor :

$$V(\hat{\beta}_{OLS}) \cdot \left[1 + \left(\frac{V(n_g)}{\bar{n}} + \bar{n} - 1 \right) \rho_x \rho_e \right] = V(\hat{\beta}_{cl})$$

→ Bootstrap

Bootstrap

↳ Monte Carlo Simulation

Introducción a bootstrap

- A veces es difícil encontrar una expresión analítica de los errores estándar
- La idea de las técnicas bootstrap es **construir una distribución empírica** del estimador de interés
- Una muestra bootstrap es una muestra tomada de los mismos datos
- En las rutinas para errores bootstrap, pensamos en $\{(y_1, x_1), \dots, (y_N, x_N)\}$ como la población
- Muestra bootstrap = muestra de tamaño N tomada de la muestra original
- El procedimiento bootstrap más usado es el bootstrap no paramétrico o bootstrap en parejas (nos enfocaremos en este tipo de bootstrap en el curso)
- La idea es remuestrear la pareja completa (y_i, x_i)

Algoritmo para errores estándar bootstrap

- 1 Dada una muestra $(y_1, x_1), \dots, (y_N, x_N)$, obtener una muestra de tamaño N , remuestreando de la muestra original **con reemplazo** (llamado método paired bootstrap o nonparametric bootstrap)

Algoritmo para errores estándar bootstrap

- 1 Dada una muestra $W_1, \dots, W_N$, obtener una muestra de tamaño N , remuestreando de la muestra original **con reemplazo** (llamado método paired bootstrap o nonparametric bootstrap)
- 2 Calcular el estadístico $\hat{\theta}_b$ usado con la muestra bootstrap (coeficiente de regresión, diferencia de medias, función de coeficientes)

Algoritmo para errores estándar bootstrap

- 1 Dada una muestra $W_1, \dots, W_N$, obtener una muestra de tamaño N , remuestreando de la muestra original **con reemplazo** (llamado método paired bootstrap o nonparametric bootstrap) *B samples with size N each*
- 2 Calcular el estadístico $\hat{\theta}_b$ usado con la muestra bootstrap (coeficiente de regresión, diferencia de medias, función de coeficientes) *a total of B $\hat{\theta}_b$'s*
- 3 Repetir los pasos 1 y 2 *B* veces, donde *B* es lo suficientemente grande (usualmente 1000 es suficiente)

Algoritmo para errores estándar bootstrap

- 1 Dada una muestra $W_1, \dots, W_N$, obtener una muestra de tamaño N , remuestreando de la muestra original **con reemplazo** (llamado método paired bootstrap o nonparametric bootstrap)
- 2 Calcular el estadístico $\hat{\theta}_b$ usado con la muestra bootstrap (coeficiente de regresión, diferencia de medias, función de coeficientes)
- 3 Repetir los pasos 1 y 2 B veces, donde B es lo suficientemente grande (usualmente 1000 es suficiente)
- 4 Usar las B repeticiones para obtener el error estándar del estadístico como la raíz cuadrada de $s_{\hat{\theta}, B}^2$:

$$s_{\hat{\theta}, B}^2 = \frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b - \bar{\hat{\theta}})^2$$

donde $\bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b$

- Se puede usar para obtener la distribución de $t^* = \frac{\hat{\theta}^* - \hat{\theta}}{s_{\hat{\theta}}^*}$ centrada en la estimación original $\hat{\theta}$.

¿Cómo hacer remuestreo en R?

```
set.seed(927)  
  
data.ingresos <- read.csv("./ingresos_iv.csv")  
  
obs <- nrow(data.ingresos)  
obs
```

```
[1] 3010
```

```
#En la muestra original  
mean(data.ingresos$lwage)
```

```
[1] 6.261832
```

¿Cómo hacer remuestreo en R?

$b = 1$

```
#Una muestra bootstrap 3010  
data.b <- data.ingresos[sample(nrow(data.ingresos), obs,  
                               replace = TRUE),]  
  
mean(data.b$lwage)
```

```
[1] 6.261918
```

$b = 2$

```
#Otra muestra bootstrap 3010  
data.b <- data.ingresos[sample(nrow(data.ingresos), obs,  
                               replace = TRUE),]  
  
mean(data.b$lwage)
```

```
[1] 6.262326
```

... $b = B = 1000$

Aplicaciones comunes de bootstrap

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, V)$$

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \rightarrow N(0, \nabla g(\theta)' V \nabla g(\theta))$$

- Métodos de varias etapas (por ejemplo, el estimador de dos etapas de Heckman)
- Funciones de estimadores (aunque aquí el método Delta también podría ser usado)
- Pensemos siempre en la estructura de los datos antes de hacer bootstrap
- Datos agrupados con pocos grupos (remuestrear grupos en vez de individuos)
- El consejo práctico es usar resultados teóricos cuando se puede (por ejemplo, las matrices robustas descritas antes)
- Usar una semilla siempre para poder reproducir sus resultados

Refinamiento asintótico

$$H_0: \beta = 0 \quad \frac{\hat{\beta} - 0}{S(\hat{\beta})} \sim t_{n-k}$$


$$H_1: \beta \neq 0$$

significance level = α

$$\frac{\hat{\theta} - 0}{S_{boot}(\hat{\theta})} \sim t_{n-k}$$

- Una aplicación de las técnicas bootstrap es el refinamiento asintótico de la prueba t de coeficientes de regresión
- Supongamos que $H_0: \beta = 0$ y trabajamos con un nivel α
- En cada repetición bootstrap el estadístico calculado es $\frac{\hat{\theta}_b - \hat{\theta}}{S(\hat{\theta}_b)}$
- Ordenamos los B estadísticos obtenidos
- Rechazamos H_0 si $|t|$ está por encima del $(1 - \alpha)$ ésimo percentil de los $|t_b|$ en la distribución bootstrap
- A pesar de sus propiedades teóricas, el refinamiento asintótico es poco usado

$|t| > |t_b|(1 - \alpha) \text{ pct} : \text{Reject } H_0$



Métodos de muestreo bootstrap

Bootstrap salvaje

Hay diferentes métodos para obtener muestras B: paired/nonparametric, parametric, residual, wild, etc.

- En presencia de heterocedasticidad se prefiere usar bootstrap salvaje (*wild bootstrap*) (MacKinnon, 2012)
- Propuesto originalmente por Liu (1988), cada muestra bootstrap tiene la siguiente forma:

→ synthetic dependent variable

$$y_i^* = X_i \hat{\beta} + f(\hat{u}_i) v_i^*$$
$$y_i = X_i \hat{\beta} + \hat{u}_i$$

- Noten que mantiene fijos los X_i en cada muestra bootstrap
- Una especificación comúnmente usada es hacer $f(\hat{u}_i) = \hat{u}_i$ y

$$v_i^* = \begin{cases} 1 & \text{con probabilidad 0.5} \\ -1 & \text{con probabilidad 0.5} \end{cases}$$

- $\hat{\beta}$ y $\hat{u}_i$ son estimados con la muestra original

$\hat{u}_i = y_i - X_i \hat{\beta}$

$X_i \hat{\beta} \pm \hat{u}_i$

$y_i, X_i, \hat{u}_i$

$\hat{u}_i = 1$
 $\hat{u}_i = 2$
 $\vdots$
 $\hat{u}_i = N$

$\begin{bmatrix} +1 \\ +1 \\ -1 \\ +1 \\ +1 \\ -1 \end{bmatrix}$

y_i^*

Bootstrap salvaje

- En cada una de las B muestras bootstrap, mantenemos a los mismos individuos (no hay remuestreo)
- Tendremos B muestras bootstrap, pero ahora la aleatoriedad viene por $f(\hat{u}_i)v_i^*$
- Pueden usarse otras funciones más complicadas para $f(\hat{u}_i)$
- La ventaja de este método es que conserva la relación entre las varianzas residuales y las X_i observadas en los datos originales
- Davidson & Flachaire (2008) utilizan simulaciones para mostrar que con esta forma para $f(\hat{u}_i)v_i^*$ la inferencia es más confiable que con otras especificaciones

Extensiones del bootstrap

- Formalmente no es un método bootstrap
- Una muestra jackknife es una muestra de tamaño $N - 1$ construida a partir de la muestra original donde una observación es eliminada a la vez
- En cada muestra jackknife estimamos el estadístico de interés $\hat{\theta}_{(j)}$ (tendremos N estadísticos)
- El error estándar jackknife será

$$\widehat{se}(\hat{\theta}) = \left(\frac{N-1}{N} \sum_{j=1}^N (\hat{\theta}_{(j)} - \hat{\theta})^2 \right)^{1/2}$$

- Funciona bien para *estadísticas suaves* y funciones lineales
- Se puede hacer jackknife por bloques (Cameron y Miller, 2015)

median
is not, for
example