

Diseños de DiD con múltiples periodos

Econometría Aplicada y Ciencia de Datos - CIDE Fall 2026

Carlos Brito

⁰El material de esta presentación se basa en Baker, A., Callaway, B., Cunningham, S., Goodman-Bacon, A., & Sant'Anna, P. H. (2025). Difference-in-differences designs: A practitioner's guide. arXiv preprint arXiv:2503.13323; De Chaisemartin, C., & d'Haultfoeuille, X. (2023). Two-way fixed effects and differences-in-differences with heterogeneous treatment effects: A survey. The econometrics journal, 26(3), C1-C30; Borusyak, K. (2025). A Modern Perspective on Difference-in-Differences Designs. Lecture Notes, UC Berkeley; Facure Alves, M. (2022). Causal Inference for the Brave and the True.

- 1 Diseños DiD con múltiples periodos
- 2 Adopción escalonada del tratamiento
- 3 Comparación de estimadores de DiD con tratamiento escalonado
- 4 Diferencias en diferencias sintéticas

Algunas definiciones y notaciones

- Tenemos que $Y_{i,t} = Y_{i,t}(0)$ para todos en los periodos pre-tratamiento.
- Observamos $Y_{i,t}(0)$ si el grupo permanece no tratado en $t = T$, y $Y_{i,t}(1)$ para los grupos tratados en una fecha de tratamiento $t = g$.
- Refirámonos a “estudio de eventos” como el estimar efectos a través de un rango de periodos de tiempo antes y después del tratamiento.


- Un diseño con un solo momento de tratamiento y múltiples periodos de tiempo (2xT) es el caso más simple de un estudio de eventos.
- Los ATTs en el periodo post-tratamiento indican cómo se mueve el efecto a lo largo del tiempo.
- Un estudio de eventos requiere la existencia de tendencias paralelas en *todo* periodo post-tratamiento.
- El cambio en $Y_{i,t}(0)$ desde $Y_{i,t=g-1}(0)$ es el mismo entre el grupo de tratamiento y control para todos los periodos post-tratamiento $t \geq g$.

$$\mathbb{E}_{\omega}[Y_{i,t}(0) - Y_{i,t=g-1}(0) \mid D_i = 1] = \mathbb{E}_{\omega}[Y_{i,t}(0) - Y_{i,t=g-1}(0) \mid D_i = 0] \quad \forall t \geq g.$$

- Evidentemente, entre más adelante nos extendamos en el periodo post-tratamiento, más difícil será que se cumpla el supuesto de tendencias paralelas para un periodo dado.

- Si se cumple el supuesto de tendencias paralelas, cada ATT se identifica comparando un periodo t con $g - 1$.

$$\widehat{ATT}(t) = (\bar{Y}_{\omega,D=1,t} - \bar{Y}_{\omega,D=1,t=g-1}) - (\bar{Y}_{\omega,D=0,t} - \bar{Y}_{\omega,D=0,t=g-1}) .$$



- Múltiples periodos de tiempo permiten hacer test de falsificación (o placebo) en los periodos pre-tratamiento (“pre-trends”).
- El supuesto de “no anticipación” implica que todos los ATTs antes de g son cero.
- Si los ATTs antes del tratamiento son cero, tenemos un apoyo al supuesto de tendencias paralelas.
- Sin embargo, no tenemos certeza de dicho supuesto, ya que estamos midiendo las tendencias en el periodo equivocado (antes del tratamiento).

Two way fixed effects (TWFE)

- Una forma de obtener todos los ATTs es con una regresión de TWFE, con efectos fijos de tiempo y unidad.
 - También añadimos interacciones entre el grupo de tratamiento y dummies de tiempo.
 - Omitimos la interacción con el tiempo $t = g - 1$ para no tener multicolinealidad.
 - Todos los estimadores β_t se interpretan respecto a $g - 1$.
-
- Los estimadores con esta regresión son iguales a los que se obtienen a mano en la ecuación para $\widehat{ATT}(t)$ anterior.

Two way fixed effects (TWFE)

- Los ATTs individuales se pueden agregar en un ATT promedio para el periodo post-tratamiento.

$$ATT_{\text{avg}} = \frac{1}{T - (g - 1)} \sum_{t=g}^T ATT(t)$$

Two way fixed effects (TWFE)

- Los ATTs individuales se pueden agregar en un ATT promedio para el periodo post-tratamiento.

$$ATT_{\text{avg}} = \frac{1}{T - (g - 1)} \sum_{t=g}^T ATT(t)$$

- Un atajo común para obtener el ATT promedio es mediante:

$$Y_{i,t} = \theta_t + \eta_i + \beta^{OLS} D_{i,t} + \varepsilon_{i,t}.$$

- donde $D_{i,t} = 1$ para las unidades tratadas en el periodo post-tratamiento.
- El estimador β^{OLS} no siempre es el mismo que $\widehat{ATT}_{\text{avg}}$, ya que en β^{OLS} se sustraen a $\widehat{ATT}_{\text{avg}}$ las estimaciones de DiD en los periodos pre-tratamiento.

- Meer, J., West, J. (2016). Effects of the minimum wage on employment dynamics. *Journal of Human Resources*, 51(2), 500-522.
- Sección 5 de Callaway, B., Sant'Anna, P. H. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200-230.
- Dobkin, C., Finkelstein, A., Kluender, R., Notowidigdo, M. J. (2018). The economic consequences of hospital admissions. *American Economic Review*, 108(2), 308-352.
- Sección 5 de Sun, L., Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of econometrics*, 225(2), 175-199.

Adopción escalonada del tratamiento


Adopción de tratamiento escalonada GxT

- Nos enfocaremos por ahora en diseños de tratamiento escalonado en que el tratamiento “se prende” en diferentes momentos para diferentes unidades, y una vez “prendido”, nunca se apaga.
- Indizamos los resultados potenciales al tiempo en el que empieza el tratamiento $Y_{i,t}(g)$.
- Usamos $Y_{i,t}(\infty)$ para denotar resultados si nunca se es tratado. Las unidades no expuestas al tratamiento para el periodo T son las “nunca tratadas”.
- G_i indica la fecha de tratamiento para la unidad i .
- En este “setting” es necesario tener un grupo nunca tratado, y también tener información pre-tratamiento para el primer grupo tratado.

- El supuesto de no anticipación con tratamiento escalonado implica que para todas las unidades i que eventualmente son tratadas y todos los periodos pre-tratamiento t , $Y_{i,t}(g) = Y_{i,t}(\infty)$.
- i.e. los efectos del tratamiento son cero en todos los periodos pre-tratamiento.

Ejemplo de tratamiento escalonado

Figure 5: County Mortality Trends by Expansion Decision with Staggered Timing



Notes: This figure shows county population-weighted average mortality rates for adults ages 20-64 from 2009 to 2019. There are 978 counties in states in the 2014 expansion group, 171 counties in the 2015 expansion group, 93 counties in the 2016 expansion group, 140 counties in the 2019 expansion group, and 1,222 counties that did not expand Medicaid by 2019.

Adopción de tratamiento escalonada GxT

- En un diseño DiD de 2x2 hay un ATT.
- En un diseño DiD 2xT, hay $T - 1$ ATTs.
- En DiD con tratamiento escalonado, cada grupo de tratamiento (o cohort) tiene su conjunto de $T - 1$ ATTs.
- Cada ATT de grupo-tiempo se define como:

$$ATT(g, t) = \mathbb{E}_{\omega} [Y_{i,t}(g) - Y_{i,t}(\infty) \mid G_i = g].$$

- Cada $ATT(g, t)$ es el ATT de empezar el tratamiento en el periodo g relativo a nunca empezarlo, en el periodo t , entre las unidades que sí empezaron el tratamiento en el periodo g .

Adopción de tratamiento escalonada GxT

- Tener grupos de tratamiento con diferentes fechas donde empieza el tratamiento permite utilizar diferentes conjuntos de grupos de comparación.
- Esto crea diferentes supuestos de tendencias paralelas. Veremos tres tipos:
 - 1 Todos los eventualmente tratados vs. los nunca tratados.
 - 2 Todos los eventualmente tratados vs. los no aún tratados.
 - 3 Para todos los grupos en todos los periodos.

- Tendencias paralelas basadas en grupos nunca tratados.
- Para todo grupo de tratamiento g eventualmente tratado y tiempo post-tratamiento $t \geq g$:

$$\mathbb{E}_\omega[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = g] = \mathbb{E}_\omega[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = \infty].$$

- Este supuesto es análogo al que revisamos en el caso 2xT.
- El supuesto impone tendencias paralelas solo para los periodos post-tratamiento. Donde el periodo $t = g - 1$ es el base.
- En el ejemplo anterior equivale a usar los condados donde no hubo expansión de Medicaid como el grupo de comparación de los grupos que tuvieron expansión en 2014, 2015, 2016 y 2019.

- Con el supuesto PT-GT-Nev, para los periodos post-tratamiento los ATT son:

$$ATT(g, t) = \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t=g-1} \mid G_i = g] - \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t=g-1} \mid G_i = \infty],$$

- Cada $ATT(g, t)$ usa datos del periodo t respecto al $g - 1$, y el grupo tratado $G_i = g$ respecto al control $G_i = \infty$.

- Tendencias paralelas basadas en grupos aún no tratados.
- Para todo grupo de tratamiento g , grupo aún no tratado g' , y tiempos t tales que $t \geq g$ y $g' > t$:

$$\mathbb{E}_{\omega}[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = g] = \mathbb{E}_{\omega}[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = g'].$$

- Bajo este supuesto, se pueden usar no solo las unidades nunca tratadas como control, sino cualquier grupo que no ha sido tratado aún en el tiempo t .

- Los ATTs son:

$$ATT(g, t) = \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t=g-1} \mid G_i = g] - \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t=g-1} \mid G_i > \max\{g, t\}].$$

- Cada $ATT(g, t)$ usa datos del periodo t respecto al $g - 1$, y el grupo tratado $G_i = g$ respecto al no tratado $G_i > t$.
- Volviendo al ejemplo: se usan los condados donde no ha habido expansión en 2016 y 2019 como grupo de comparación cuando se estima el $ATT(2014, 2015)$.
- Para identificar el ATT para los condados donde hubo expansión de Medicaid en 2015, podemos usar los condados nunca tratados, los tratados en 2016 o los tratados en 2019, y usar cualquier año de 2009 a 2014 como base.

- Tendencias paralelas basadas para todo periodo y grupo.
- Para todo grupo de tratamiento g y g' , y tiempos t :

$$\mathbb{E}_{\omega}[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = g] = \mathbb{E}_{\omega}[Y_{i,t}(\infty) - Y_{i,t-1}(\infty) \mid G_i = g'].$$

- Bajo este supuesto, se puede usar cualquier grupo aún no tratado como grupo de control, y cualquier tiempo pre-tratamiento como periodo base.

- Para todo periodo pre-tratamiento $t_{\text{pre}} < g$ y cualquier grupo aún no tratado $g' > t$, el $ATT(g, t)$ del grupo g para el periodo post-tratamiento ($t \geq g$) es:

$$ATT(g, t) = \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t_{\text{pre}}} \mid G_i = g] - \mathbb{E}_{\omega}[Y_{i,t} - Y_{i,t_{\text{pre}}} \mid G_i = g'],$$

- Cada $ATT(g, t)$ usa datos del periodo t (post) respecto al t_{pre} , y el grupo tratado $G_i = g$ respecto al no tratado $G_i > g'$.
- Así, se pueden usar varios periodos pre-tratamiento y varios grupos aún no tratados para caracterizar el $ATT(g, t)$.

¿Cuál supuesto usar?

- El supuesto PT-GT-all usa datos de múltiples periodos pre-tratamiento y múltiples grupos de comparación.
 - Esto lleva a tener más observaciones, por ende estimadores más precisos.
 - Sin embargo, impone pre-tendencias paralelas, un supuesto más fuerte que en otros casos (incluso el 2xT).

¿Cuál supuesto usar?

- El supuesto PT-GT-all usa datos de múltiples periodos pre-tratamiento y múltiples grupos de comparación.
 - Esto lleva a tener más observaciones, por ende estimadores más precisos.
 - Sin embargo, impone pre-tendencias paralelas, un supuesto más fuerte que en otros casos (incluso el 2xT).
- El supuesto PT-GT-Nev es mucho menos exigente: evita cambios de composición en el grupo de control, y no necesita pre-tendencias.
 - Sin embargo, las unidades nunca tratadas posiblemente fueron nunca tratadas por razones ligadas a la variable dependiente Y .
 - Los nunca tratados pueden ser demasiado diferentes a los tratados para reflejar un contrafactual relevante.
 - También pueden ser pocas unidades, lo que dificulta la precisión.


¿Cuál supuesto usar?

- El supuesto PT-GT-all usa datos de múltiples periodos pre-tratamiento y múltiples grupos de comparación.
 - Esto lleva a tener más observaciones, por ende estimadores más precisos.
 - Sin embargo, impone pre-tendencias paralelas, un supuesto más fuerte que en otros casos (incluso el $2 \times T$).
- El supuesto PT-GT-Nev es mucho menos exigente: evita cambios de composición en el grupo de control, y no necesita pre-tendencias.
 - Sin embargo, las unidades nunca tratadas posiblemente fueron nunca tratadas por razones ligadas a la variable dependiente Y .
 - Los nunca tratados pueden ser demasiado diferentes a los tratados para reflejar un contrafactual relevante.
 - También pueden ser pocas unidades, lo que dificulta la precisión.
- Una solución intermedia puede ser PT-GT-NYT.
 - Usa más información que PT-GT-Nev.
 - Es menos exigente que PT-GT-all.

- Estimador de Callaway & Sant'Anna¹ con los aún no tratados como control:

$$\widehat{ATT}_{\text{nyt}}(g, t) = \frac{\sum_{i=1}^n 1\{G_i = g\} \omega_i (Y_{i,t} - Y_{i,t=g-1})}{\sum_{i=1}^n 1\{G_i = g\} \omega_i} - \frac{\sum_{i=1}^n 1\{G_i > t\} \omega_i (Y_{i,t} - Y_{i,gt=-1})}{\sum_{i=1}^n 1\{G_i > t\} \omega_i}.$$

¹Callaway, B., & Sant'Anna, P. H. (2021). Difference-in-differences with multiple time periods. *Journal of econometrics*, 225(2), 200-230.

Figure 6: $ATT(g,t)$ s for Each Expansion Group

Notes: This figure shows the group-time ATT estimates ($ATT(g,t)$) in calendar time for the four groups of counties that expanded Medicaid before 2019. Each panel uses 1,222 not-yet-treated counties as the comparison group and shows their uniform confidence intervals at the 95% significance level. There are 978 counties in states in the 2014 expansion group, 171 counties in the 2015 expansion group, 93 counties in the 2016 expansion group, 140 counties in the 2019 expansion group. The outcome variable is the crude mortality rate for adults ages 20-64, and standard errors are clustered at the county level. The vertical line represents the year before Medicaid expansion (i.e., $g - 1$) for the timing group. All results use population weights.

- Estimador de Callaway & Sant'Anna con los nunca tratados como control:

$$\widehat{ATT}_{\text{never}}(g, t) = \frac{\sum_{i=1}^n 1\{G_i = g\} \omega_i (Y_{i,t} - Y_{i,t=g-1})}{\sum_{i=1}^n 1\{G_i = g\} \omega_i} - \frac{\sum_{i=1}^n 1\{G_i = \infty\} \omega_i (Y_{i,t} - Y_{i,gt=-1})}{\sum_{i=1}^n 1\{G_i = \infty\} \omega_i}$$

- Estimador de Sun & Abraham²:

$$Y_{i,t} = \theta_t + \eta_i + \sum_{g \neq \infty} \sum_{e \neq -1} \beta_{g,e}^{SA} 1\{G_i = g\} 1\{G_i + e = t\} + \epsilon_{i,t}.$$

- Se ha mostrado que:

$$\beta_{g,e}^{SA} = \widehat{ATT}_{\text{never}}(g, g + e)$$

²Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of econometrics*, 225(2), 175-199.

- Estimador de Callaway & Sant'Anna:


$$\widehat{ATT}_{\text{avg}}(g, t) = \frac{\sum_{i=1}^n 1\{G_i = g\} \omega_i (Y_{i,t} - \bar{Y}_{i,t \leq g-1})}{\sum_{i=1}^n 1\{G_i = g\} \omega_i} - \frac{\sum_{i=1}^n 1\{G_i > t\} \omega_i (Y_{i,t} - \bar{Y}_{i,t \leq g-1})}{\sum_{i=1}^n 1\{G_i > t\} \omega_i}$$

- Estimador de Wooldridge³:

$$Y_{i,t} = \theta_t + \eta_i + \sum_{g \neq \infty} \sum_{s=g}^T \beta_{g,t}^W 1\{G_i = g\} 1\{s = t\} + \epsilon_{i,t},$$

³Wooldridge, J. M. (2025). Two-way fixed effects, the two-way mundlak regression, and difference-in-differences estimators: JM Wooldridge. *Empirical Economics*, 1-43.


- La agregación en tratamiento escalonado implica tomar en cuenta:
 - El tiempo (ya sea calendario t , o el **tiempo-evento** $e = t - g$).
 - Una duración de tiempo (para cuántos periodos se va a agregar).
 - Pesos grupales (para que los grupos grandes pesen más).
- Cada pieza $ATT(g, t)$ se puede usar para crear muchos agregados:

Figure 7: $ATT(g, t)$ in Event Time

Notes: This figure shows the group-time ATT estimates ($ATT(g, t)$) in relative event time for the four treatment timing groups of counties that expanded Medicaid before 2019, using not-yet-treated units as the comparison group. The outcome variable is the crude mortality rate for adults ages 20-64. All estimates use population weights.

Agregación de los estimadores

- La figura anterior centra los $ATT(g, t)$ en **tiempo-evento** en vez de tiempo-calendario.
- Se grafica $ATT(g, g + e)$ para cada e para cada grupo de tratamiento.
- Se pueden tomar promedios ponderados de forma **“vertical”** para cada $ATT(g, g + e)$ para cada evento e .
 - En el tiempo-evento 0 se promedian los estimadores $ATT(2014, 2014)$, $ATT(2015, 2015)$, $ATT(2016, 2016)$ y $ATT(2019, 2019)$
 - En el tiempo-evento 1 se promedian $ATT(2014, 2015)$, $ATT(2015, 2016)$, $ATT(2016, 2017)$.
 - ...y así.

Figure 8: $G \times T$ Event Study without Covariates

Notes: This figure shows the event study estimates with staggered treatment timing using the doubly-robust estimation method from Callaway and Sant'Anna (2021), using 1,222 not-yet-treated units as the comparison group. The sample sizes used to estimate ATT parameters for each timing group are 2,200 for the 2014 group, 1,393 for the 2015 group, 1,315 for the 2016 group, and 1,362 for the 2019 group. The outcome variable is the crude mortality rate for adults ages 20-64. The point estimate is reported by the circles, and both 95% point-wise (black) and simultaneous (red) confidence intervals are reported with the vertical lines. We also report the simple average of all non-negative event times as a summary of the overall ATT (together with their standard errors and 95% confidence interval). All results use population weights.

Agregación de los estimadores

- En términos de tiempo-evento el ATT promedio es:

$$ATT_{es}(e) = \mathbb{E}_{\omega} [ATT(G, G + e) \mid G + e \in [1, T], G \leq T] = \sum_{g < \infty} w_{\omega, g, e}^{es} ATT(g, g + e),$$

- donde $w_{g, e}^{es}$ es la proporción de un grupo $G = g$ entre las unidades tratadas que han sido expuestas al tratamiento por e periodos.
- El $ATT_{es}(e)$ da el efecto de tratamiento promedio para las unidades tratadas que han sido expuestas al tratamiento por e periodos.
- También se puede tomar un promedio simple en todos los eventos post-tratamiento, $ATT_{es}(e) \geq 0$ y reportar el ATT promedio para todos los periodos.

Comparación de estimadores de DiD con tratamiento escalonado

Estimadores robustos a la heterogeneidad en el tratamiento

- Los estimadores alternativos a **TWFE** necesitan del supuesto de tendencias paralelas, pero no **necesitan que no exista heterogeneidad del tratamiento en el tiempo**.
- Todos escogen un grupo de control que **evite las “comparaciones prohibidas”** que llevan a TWFE a no ser robusto a heterogeneidad del tratamiento.
- Recordemos las comparaciones relevantes en un TWFE

$$\begin{aligned}\hat{\delta}_{kU}^{2 \times 2} &= \left(\bar{y}_k^{\text{post}(k)} - \bar{y}_k^{\text{pre}(k)} \right) - \left(\bar{y}_U^{\text{post}(k)} - \bar{y}_U^{\text{pre}(k)} \right) \\ \hat{\delta}_{kl}^{2 \times 2} &= \left(\bar{y}_k^{\text{mid}(k,l)} - \bar{y}_k^{\text{pre}(k)} \right) - \left(\bar{y}_l^{\text{mid}(k,l)} - \bar{y}_l^{\text{pre}(k)} \right) \\ \hat{\delta}_{lk}^{2 \times 2} &= \left(\bar{y}_l^{\text{post}(l)} - \bar{y}_l^{\text{mid}(k,l)} \right) - \left(\bar{y}_k^{\text{post}(l)} - \bar{y}_k^{\text{mid}(k,l)} \right)\end{aligned}$$

- El primer 2x2 es cualquier tratado (k o l) comparado con el no tratado (U). El segundo es un grupo ya tratado comparado con un grupo por tratar. El tercero es un grupo aún no tratado comparado con un grupo ya tratado.
- Las comparaciones prohibidas son las: $\hat{\delta}_{lk}^{2 \times 2}$. I.e. Comparaciones *late-to-early*.

Estimadores que excluyen efectos dinámicos

- Asumen que el resultado de un grupo solo depende del tratamiento actual.
- Otra forma de decirlo: los tratamientos pasados no afectan el resultado hoy.
- Con tratamiento binario: de Chaisemartin & D'Haultfoeuille (2020).⁴
- Con tratamiento continuo: de Chaisemartin et al. (2022).⁵

⁴De Chaisemartin, C., & d'Haultfoeuille, X. (2020). Two-way fixed effects estimators with heterogeneous treatment effects. *American economic review*, 110(9), 2964-2996.

⁵de Chaisemartin, C., d'Haultfoeuille, X., Pasquier, F., Sow, D., & Vazquez-Bare, G. (2022). Difference-in-differences estimators for treatments continuously distributed at every period. arXiv preprint arXiv:2201.06898.

- Proponen un estimador DID_M que es un promedio ponderado de DID_+ y DID_- :
- DID_+ compara Y en el periodo 1-a-2, para los grupos que pasan de no tratados a tratados (“switchers-in”), y los grupos no tratados en ambos periodos.
 - Es equivalente a una comparación de DiD típica 2x2.

$$DID_+ = \frac{1}{N_{0,1}} \sum_{g:D_{g,1}=0, D_{g,2}=1} (Y_{g,2} - Y_{g,1}) - \frac{1}{N_{0,0}} \sum_{g:D_{g,1}=0, D_{g,2}=0} (Y_{g,2} - Y_{g,1}),$$

- Proponen un estimador DID_M que es un promedio ponderado de DID_+ y DID_- :
- DID_+ compara Y en el periodo 1-a-2, para los grupos que pasan de no tratados a tratados (“switchers-in”), y los grupos no tratados en ambos periodos.
 - Es equivalente a una comparación de DiD típica 2x2.

$$DID_+ = \frac{1}{N_{0,1}} \sum_{g:D_{g,1}=0, D_{g,2}=1} (Y_{g,2} - Y_{g,1}) - \frac{1}{N_{0,0}} \sum_{g:D_{g,1}=0, D_{g,2}=0} (Y_{g,2} - Y_{g,1}),$$

- DID_- compara a Y en el periodo 1-a-2, para los grupos tratados en ambos periodos, y los grupos que pasan de tratados a no tratados (“switchers-out”).

$$DID_- = \frac{1}{N_{1,1}} \sum_{g:D_{g,1}=1, D_{g,2}=1} (Y_{g,2} - Y_{g,1}) - \frac{1}{N_{1,0}} \sum_{g:D_{g,1}=1, D_{g,2}=0} (Y_{g,2} - Y_{g,1}),$$

- Así, el estimador de Chaisemartin & D'Haultfoeuille (2020) **permite que el tratamiento “se prenda” y “se apague”**.

- i son grupos, h es cuando empieza el tratamiento.
- de Chaisemartin & D'Haultfoeuille (2020) calculan para $h = 0$:

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$	$h = 0$			
$t = 3$		$h = 0$		
$t = 4$				
$t = 5$			$h = 0$	
$t = 6$				

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$	$h = 0$			
$t = 3$		$h = 0$		
$t = 4$				
$t = 5$			$h = 0$	
$t = 6$				

- Para cada grupo, se calcula un ATT usando a los aún no tratados (o nunca tratados).
- Se compara respecto al periodo justo antes, ignorando los demás periodos.

- DID_M se puede extender a aplicaciones con más de dos periodos.
- Para cada par de periodos se calcula un $DID_{+,t}$ que compara a grupos que pasan de no tratados a tratados de $t - 1$ a t , contra grupos no tratados en ambas fechas.
- Para cada par de periodos también se calcula un $DID_{-,t}$ comparando grupos tratados en $t - 1$ y t , contra grupos que pasan de tratados a no tratados de $t - 1$ a t .
- Después se promedian los $DID_{+,t}$ y $DID_{-,t}$ a través de t .

- Con más de dos periodos, el estimador DID_M puede estar sesgado:
 - Para inferir el contrafactual que tendrían los grupos que pasan de no tratados a tratados de $t - 1$ a t , el $DID_{+,t}$ usa como control a todos los grupos no tratados en $t - 1$ y t .
 - Sin embargo, algunos de esos grupos pudieron haber sido tratados en, por ejemplo, $t - 2$.
 - Con efectos dinámicos, este tratamiento pasado puede afectar a Y en el periodo $t - 1$ a t . Lo que los puede hacer controles inválidos.

Estimadores que permiten efectos dinámicos

- El resultado de un grupo g en un tiempo t puede depender de tratamientos pasados.
- $Y_{g,t}(0_t)$ es el resultado del grupo g si nunca es tratado.
- El supuesto de tendencias paralelas se vuelve:

$$E[Y_{g,t}(0_t) - Y_{g,t-1}(0_{t-1})] = E[Y_{g',t}(0_t) - Y_{g',t-1}(0_{t-1})].$$

- Los grupos se pueden agregar en cohortes que empiezan a recibir el tratamiento en el mismo periodo.
- Para toda c y t y $l \in [0, \dots, t]$, $\bar{Y}_{c,t}$ es el resultado promedio en el periodo t para la cohorte c . $\bar{Y}_{n,t}$ es el resultado promedio en t para los nunca tratados.
- El parámetro de interés es:

$$TE_{c,c+l} = E \left[\bar{Y}_{c,c+l}(0_{c-1}, 1_{l+1}) - \bar{Y}_{c,c+l}(0_{c+l}) \right],$$

- I.e., el efecto promedio de haber sido tratado por $l + 1$ periodos en la cohorte que empezó a recibir el tratamiento en c .

- Para estimar, por ejemplo $TE_{c,c}$ proponen:

$$\overline{DID}_{c,0} = \overline{Y}_{c,c} - \overline{Y}_{c,c-1} - (\overline{Y}_{n,c} - \overline{Y}_{n,c-1}),$$

- El estimador DID compara el periodo $c - 1$ al c en la cohorte c , contra los grupos nunca tratados n .

- Para estimar, por ejemplo $TE_{c,c}$ proponen:

$$\overline{DID}_{c,0} = \overline{Y}_{c,c} - \overline{Y}_{c,c-1} - (\overline{Y}_{n,c} - \overline{Y}_{n,c-1}),$$

- El estimador DID compara el periodo $c - 1$ al c en la cohorte c , contra los grupos nunca tratados n .
- Más generalmente:

$$\overline{DID}_{c,\ell} = \overline{Y}_{c,c+\ell} - \overline{Y}_{c,c-1} - (\overline{Y}_{n,c+\ell} - \overline{Y}_{n,c-1}),$$

- Se compara el periodo $c - 1$ al $c + \ell$ en la cohorte c , contra los grupos nunca tratados n .
- Adicional: se pueden cambiar los “nunca tratados” por “aún no tratados” en el periodo c .

- También proponen un efecto de tratamiento específico a cohortes: $TE_{c,c+l}$.
- Siempre usan a los nunca tratados como control.
- No proponen usar los aún no tratados como control.
- Muestran que su estimador se puede obtener mediante una regresión lineal.

Callaway & Sant'Anna (2021); Sun & Abraham (2021) - nunca tratados

- Para toda $h \geq 0$:

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$				
$t = 3$	$h = 1$			
$t = 4$		$h = 1$		
$t = 5$				
$t = 6$			$h = 1$	

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$				
$t = 3$	$h = 1$			
$t = 4$		$h = 1$		
$t = 5$				
$t = 6$			$h = 1$	

- Para cada cohorte c se toma el grupo de control de los nunca tratados.

Callaway & Sant'Anna (2021) - aún no tratados

- Para toda $h \geq 0$:

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$				
$t = 3$	$h = 1$			
$t = 4$		$h = 1$		
$t = 5$				
$t = 6$			$h = 1$	

	$i = A$	$i = B$	$i = C$	$i = D$
$t = 1$				
$t = 2$				
$t = 3$	$h = 1$			
$t = 4$		$h = 1$		
$t = 5$				
$t = 6$			$h = 1$	


- Para cada cohorte c se forma un grupo de control con las cohortes aún no tratadas en $c + h$.

- Brynjolfsson, E., Li, D., Raymond, L. (2025). Generative AI at work. The Quarterly Journal of Economics, 140(2), 889-942 + Online Appendix.

Diferencias en diferencias sintéticas

- Analizaremos como ejemplo el efecto de un impuesto al tabaco (Proposition 99) en California, sobre el consumo de cigarros.
- El impuesto consistió en 25 centavos por cajetilla, y una cantidad equivalente para otros productos del tabaco.
- La ley toma efecto en noviembre de 1988.
- El grupo de control serán los demás Estados.

Estimación con diferencias en diferencias



- El supuesto de tendencias paralelas parece no cumplirse. La tendencia de consumo de cigarros es diferente en California vs. el resto de los Estados.
- El estimador de DiD sobre-estima el efecto del impuesto.

Estimación con diferencias en diferencias

- Recordemos: el estimador de DiD se puede obtener con un TWFE, que se puede representar de la siguiente forma:

$$\hat{\tau}^{did} = \underset{\mu, \alpha, \beta, \tau}{\operatorname{argmin}} \left\{ \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it}))^2 \right\}$$

- Para implementarlo, se pueden agregar dummies de tiempo y unidad, o se pueden restar las medias (demean):

$$\ddot{Y}_{it} = Y_{it} - \bar{Y}_i - \bar{Y}_t \qquad \ddot{D}_{it} = D_{it} - \bar{D}_i - \bar{D}_t$$

- Con $\bar{Y}_i$ el promedio por unidad a través del tiempo, y $\bar{Y}_t$ el promedio por periodo a través de las unidades.

- La estimación por control sintético es un problema similar:
 - 1 Encontramos pesos para cada unidad que minimicen la diferencia en Y del pre-tratamiento entre las unidades tratadas y de control.

$$\hat{w}^{sc} = \underset{w}{\operatorname{argmin}} \|\bar{\mathbf{y}}_{pre,tr} - \mathbf{Y}_{pre,co} \mathbf{w}_{co}\|_2^2 \quad \text{s.t.} \quad \sum w_i = 1 \text{ and } w_i \geq 0 \quad \forall i$$

- La estimación por control sintético es un problema similar:
 - 1 Encontramos pesos para cada unidad que minimicen la diferencia en Y del pre-tratamiento entre las unidades tratadas y de control.

$$\hat{w}^{sc} = \underset{w}{\operatorname{argmin}} \|\bar{y}_{pre,tr} - Y_{pre,co} w_{co}\|_2^2 \quad \text{s.t.} \quad \sum w_i = 1 \text{ and } w_i \geq 0 \quad \forall i$$


- 2 Una vez que se encuentran los pesos que resuelven el problema anterior, se multiplican por las unidades de control en todos los periodos de tiempo para obtener un control sintético de la unidad tratada:

$$y_{sc} = Y_{co} \hat{w}^{sc}$$

- Lo que buscamos es que $y_{post,sc}$ sea una buena estimación del resultado potencial que no vemos $Y(0)_{post,tr}$.
- Así, el ATT es el promedio de la unidad tratada en el post-tratamiento, menos el control sintético:

$$\hat{\tau} = \bar{y}_{post,tr} - \bar{y}_{post,sc}$$

Control sintético



- El control sintético fuerza tendencias paralelas en el periodo pre-tratamiento.
- La diferencia entre las líneas punteadas es el ATT.

- Podemos re-expresar el control sintético de una forma similar al TWFE:

$$\hat{\tau}^{sc} = \underset{\beta, \tau}{\operatorname{argmin}} \left\{ \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - \beta_t - \tau D_{it})^2 \hat{w}_i^{sc} \right\}$$

- donde los pesos $\hat{w}_i^{sc}$ se estiman con el problema de optimización anterior.
- Diferencias de CS vs. DiD:
 - SC añade los pesos $\hat{w}_i^{sc}$.
 - Hay efectos fijos de tiempo, pero no de unidad, tampoco intercepto.

Diferencias en diferencias sintéticas

- Los problemas de DiD y CS son:

$$\hat{\tau}^{sc} = \operatorname{argmin}_{\beta, \tau} \left\{ \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - \beta_t - \tau D_{it})^2 \hat{w}_i^{sc} \right\}$$

$$\hat{\tau}^{did} = \operatorname{argmin}_{\mu, \alpha, \beta, \tau} \left\{ \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it}))^2 \right\}$$

- Para DiD sintéticas⁶, añadiremos pesos al estimador DiD, o efectos fijos de unidad al CS.

$$\hat{\tau}^{sdid} = \operatorname{argmin}_{\mu, \alpha, \beta, \tau} \left\{ \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - (\mu + \alpha_i + \beta_t + \tau D_{it}))^2 \hat{w}_i^{sdid} \hat{\lambda}_t^{sdid} \right\}$$

- Notemos que en DiD sintéticas también tenemos pesos de tiempo $\hat{\lambda}_t$.

⁶Arkhangelsky, D., Athey, S., Hirshberg, D. A., Imbens, G. W., & Wager, S. (2021). Synthetic difference-in-differences. *American Economic Review*, 111(12), 4088-4118.

Pesos de tiempo

- En control sintético, los pesos $\hat{w}_i$ minimizan la diferencia en Y entre las unidades de tratamiento y control en el periodo pre-tratamiento.
- Los pesos de tiempo hacen algo similar para los periodos: minimizan la diferencia entre los periodos pre y post-tratamiento para el control.

$$\hat{\lambda}^{sdid} = \underset{\lambda}{\operatorname{argmin}} \|\bar{\mathbf{y}}_{post,co} - (\lambda_{pre} \mathbf{Y}_{pre,co} + \lambda_0)\|_2^2 \quad \text{s.t.} \quad \sum \lambda_t = 1 \text{ and } \lambda_t \geq 0 \forall t$$


Pesos de tiempo

- En control sintético, los pesos $\hat{w}_i$ minimizan la diferencia en Y entre las unidades de tratamiento y control en el periodo pre-tratamiento.
- Los pesos de tiempo hacen algo similar para los periodos: minimizan la diferencia entre los periodos pre y post-tratamiento para el control.

$$\hat{\lambda}^{sdid} = \underset{\lambda}{\operatorname{argmin}} \|\bar{\mathbf{y}}_{post,co} - (\lambda_{pre} \mathbf{Y}_{pre,co} + \lambda_0)\|_2^2 \quad \text{s.t.} \quad \sum \lambda_t = 1 \text{ and } \lambda_t \geq 0 \forall t$$

¿Por qué ayudan los pesos de tiempo?

- **Menor sesgo:** si las tendencias no son perfectamente paralelas, los periodos pre-tratamiento lejanos son una mala línea base. Dar más peso a los periodos más parecidos al post-tratamiento hace la comparación más creíble.
- **Doble robustez:** el estimador funciona bien si *alguno* de los dos conjuntos de pesos (de unidad o de tiempo) logra un buen balance.
- **Precisión:** descartar periodos poco informativos reduce el ruido.



- El promedio ponderado de los tres años anteriores al tratamiento (mostrados con barras) es suficiente para balancear los periodos pre y post-tratamiento.

Pesos de unidad

- Los pesos de unidad w_i de control sintético

$$\hat{w}^{sc} = \underset{w}{\operatorname{argmin}} \|\bar{\mathbf{y}}_{pre,tr} - \mathbf{Y}_{pre,co} \mathbf{w}_{co}\|_2^2 \quad \text{s.t.} \quad \sum w_i = 1 \text{ and } w_i \geq 0 \forall i$$

- Los pesos de unidad w_i son similares a los de control sintético, pero no iguales.



$$\hat{w}^{sdid} = \underset{w}{\operatorname{argmin}} \|\bar{\mathbf{y}}_{pre,tr} - (\mathbf{Y}_{pre,co} \mathbf{w}_{co} + w_0)\|_2^2 + \zeta^2 T_{pre} \|\mathbf{w}_{co}\|_2^2 \quad \text{s.t.} \quad \sum w_i = 1 \text{ and } w_i \geq 0 \forall i$$

- Resaltemos que en SDID se permite un intercepto w_0 .
- En SDID el tratamiento y el control sintético no necesitan tener el mismo nivel, solo es necesario que la unidad tratada y el control sintético tengan tendencias paralelas.

El término $\zeta^2 T_{pre} \|\mathbf{w}_{co}\|_2^2$ es una penalización tipo ridge:


- Reparte los pesos entre más unidades de control.
- Reduce la varianza y evita sobreajustar el ruido del pre-tratamiento.
- Garantiza que la solución sea única.

CS vs. SDID



- En SDiD, el intercepto permite que la unidad sintética esté en un nivel diferente a la tratada.
- En el post-tratamiento, CS y SDiD no son iguales, ya que los pesos se calculan de manera diferente.

Efecto del tratamiento en SDID



- Proyectamos el cambio que vemos en la unidad tratada al control sintético.
- La diferencia entre las líneas sólida y punteada moradas es el ATT.

Efecto en el tiempo

- Con SDID, se puede calcular el efecto para cada periodo de tiempo, calculándolo múltiples veces: una vez para cada periodo.
- Supongamos que tenemos 4 periodos, y 3 unidades, con una de ellas tratada en los periodos 3 y 4.

$$D = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 0_4 & 1_4 \end{bmatrix}$$

- Estimar el SDID implica particionar la matriz y calcularlo para cada una:

$$D_1 = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{bmatrix} \quad D_2 = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 0_4 & 1_4 \end{bmatrix}$$

- Esto se puede extender al tratamiento escalonado. Supongamos que tenemos:

$$D = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \\ 0_4 & 1_4 & 1_4 \end{bmatrix}$$

- SDID no puede calcular esa matriz porque no hay un periodo de pre-tratamiento claro. Es antes de $t = 4$ para la segunda unidad, pero antes de $t = 3$ para la tercera.
- Se pueden quitar columnas (unidades) o filas (periodos) para resolver esto.

- Una solución:

$$D_1 = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_4 & 1_4 & 1_4 \end{bmatrix} \quad D_2 = \begin{bmatrix} 0_1 & 0_1 & 0_1 \\ 0_2 & 0_2 & 0_2 \\ 0_3 & 0_3 & 1_3 \end{bmatrix}$$

- Corremos el SDID para cada bloque, y tenemos dos ATTs.
- Estos se pueden combinar en un promedio ponderado (proporción de tratamiento en cada bloque).
- En el ejemplo el ATT_1 vale $2/3$, el ATT_2 vale $1/3$.

- Otra solución:

$$D_1 = \begin{bmatrix} 0_1 & 0_1 \\ 0_2 & 0_2 \\ 0_3 & 0_3 \\ 0_4 & 1_4 \end{bmatrix} \quad D_2 = \begin{bmatrix} 0_1 & 0_1 \\ 0_2 & 0_2 \\ 0_3 & 1_3 \\ 0_4 & 1_4 \end{bmatrix}$$

- Donde D_1 tiene las unidades 1 y 2, y D_2 tiene las 1 y 3.

- Li, G., Fang, C., Watson, J. E., Sun, S., Qi, W., Wang, Z., Liu, J. (2024). Mixed effectiveness of global protected areas in resisting habitat loss. *Nature Communications*, 15(1), 8389.