

Diseños de DiD con múltiples periodos

Econometría Aplicada y Ciencia de Datos - CIDE Fall 2026

Carlos Brito

⁰El material de esta presentación se basa en Baker, A., Callaway, B., Cunningham, S., Goodman-Bacon, A., & Sant'Anna, P. H. (2025). Difference-in-differences designs: A practitioner's guide. arXiv preprint arXiv:2503.13323; De Chaisemartin, C., & d'Haultfoeuille, X. (2023). Two-way fixed effects and differences-in-differences with heterogeneous treatment effects: A survey. The Econometrics Journal, 26(3), C1-C30; Borusyak, K. (2025). A Modern Perspective on Difference-in-Differences Designs. Lecture Notes, UC Berkeley; Facure Alves, M. (2022). Causal Inference for the Brave and the True.

- 1 Motivación
- 2 Estimador de imputación
- 3 Comparación de estimadores
- 4 Tratamientos no binarios o no escalonados

Motivación

Motivación: el problema del TWFE (Repaso)

- Regresión TWFE estándar con tratamiento escalonado:

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it}$$

- Si los efectos son heterogéneos entre cohortes o en el tiempo, $\hat{\beta}$ puede no ser un promedio convexo de efectos de tratamiento.
- Origen: **comparaciones prohibidas**. Unidades ya tratadas se usan como controles de unidades tratadas más tarde.
- Con efectos dinámicos, algunos pesos pueden ser **negativos**.
- Solución: estimadores robustos a heterogeneidad.
 - Callaway y Sant'Anna (2021); Sun y Abraham (2021)
 - Borusyak, Jaravel y Spiess (2024); Gardner (2021); Liu et al. (2024)

Estimador de imputación

Borusyak, Jaravel y Spiess (2024)

Notación: observaciones tratadas y no tratadas

- E_i : periodo en que la unidad i adopta el tratamiento ($E_i = \infty$ si nunca se trata).
- Indicador de tratamiento (escalonado, absorbente): $D_{it} = 1\{t \geq E_i\}$.
- Particionamos el panel en dos conjuntos de observaciones (i, t) :

$$\Omega_0 = \{(i, t) : D_{it} = 0\} \quad (\text{no tratadas}), \quad \Omega_1 = \{(i, t) : D_{it} = 1\} \quad (\text{tratadas})$$

- Ω_0 incluye las nunca tratadas **y** los periodos **previos** a la adopción de las que se tratan después.
- $\Omega_{1,h} = \{(i, t) \in \Omega_1 : t - E_i = h\}$: observaciones tratadas h periodos después de adoptar.

	$t = 1$	$t = 2$	$t = 3$	$t = 4$	$t = 5$
A ($E_A = 3$)	0	0	1	1	1
B ($E_B = 4$)	0	0	0	1	1
C ($E_C = \infty$)	0	0	0	0	0

- **Azul**: $(i, t) \in \Omega_0$, se observa $Y_{it}(0)$.
- **Rojo**: $(i, t) \in \Omega_1$, falta $Y_{it}(0)$ y hay que imputarlo.
- Ej.: $\Omega_{1,0} = \{(A, 3), (B, 4)\}$.

Borusyak, Jaravel y Spiess: la idea

- Tratar el problema como uno de **datos faltantes**: para observaciones tratadas, $Y_{it}(0)$ no se observa.
- Efecto individual: $\tau_{it} = Y_{it} - Y_{it}(0)$ para cada $(i, t) \in \Omega_1$.
- Estimando objetivo: un promedio ponderado

$$\tau_w = \sum_{(i,t) \in \Omega_1} w_{it} \tau_{it}$$

(p.ej., el efecto promedio h periodos después de la adopción).

- Idea: usar **solo** las observaciones de Ω_0 para estimar el modelo de $Y(0)$ e imputar el contrafactual.
- Nunca se usan observaciones **ya tratadas** (Ω_1) como controles $\Rightarrow$ no hay comparaciones prohibidas.

- 1 **Tendencias paralelas** (modelo para $Y(0)$):

$$\mathbb{E}[Y_{it}(0)] = \alpha_i + \lambda_t \quad \text{para todo } (i, t)$$

Puede extenderse con covariables o tendencias lineales por unidad.

- 2 **No anticipación:** $Y_{it} = Y_{it}(0)$ para todo $(i, t) \in \Omega_0$.

Nota: se requieren observaciones no tratadas en cada periodo usado. Sin unidades nunca tratadas, los efectos de horizontes largos pueden no estar identificados.

El estimador en tres pasos

- ❶ **Estimar** efectos fijos usando solo las observaciones no tratadas, Ω_0 :

$$Y_{it} = \alpha_i + \lambda_t + \varepsilon_{it}, \quad (i, t) \in \Omega_0$$

- ❷ **Imputar** el contrafactual y el efecto individual:

$$\hat{Y}_{it}(0) = \hat{\alpha}_i + \hat{\lambda}_t, \quad \hat{\tau}_{it} = Y_{it} - \hat{Y}_{it}(0), \quad (i, t) \in \Omega_1$$

- ❸ **Agregar**:

$$\hat{\tau}_w = \sum_{(i,t) \in \Omega_1} w_{it} \hat{\tau}_{it}$$

- Event study: $w_{it} = 1/|\Omega_{1,h}|$ si $(i, t) \in \Omega_{1,h}$ y 0 en otro caso.

- **Eficiencia:** bajo errores homocedásticos y no correlacionados (Gauss–Markov), el estimador de imputación es el **más eficiente** entre los estimadores lineales insesgados.
- **Equivalencias:** coincide numéricamente con el *two-stage DiD* de Gardner (2021) y con el estimador de Liu et al. (2024).
- **Pre-tendencias:** el test se hace por separado, solo con Ω_0 :

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k=1}^K \gamma_k 1\{t - E_i = -k\} + \varepsilon_{it}$$

Así, la prueba de pre-tendencias no contamina la estimación de los efectos.

- **Inferencia:** errores estándar asintóticos (agrupados), conservadores cuando los efectos son heterogéneos.

Stata

```
ssc install did_imputation  
did_imputation Y i t Ei, horizons(0/5) pretrends(5) autosample
```

R

```
install.packages("didimputation")  
did_imputation(data = df, yname = "Y", gname = "Ei",  
               tname = "t", idname = "i", horizon = TRUE)
```

- Ei: periodo de adopción (missing o 0 para nunca tratadas).
- Alternativa: did2s (Gardner) en Stata y R.

Comparación de estimadores

¿En qué difieren los estimadores?

de Chaisemartin y D'Haultfœuille (2023)

1. Eficiencia

- Borusyak et al. puede ser más preciso que Callaway–Sant’Anna y Sun–Abraham bajo supuestos de Gauss–Markov.
- Con correlación serial la garantía de eficiencia se pierde, aunque las simulaciones muestran ganancias con correlación moderada.

2. Supuesto de tendencias paralelas

- **Borusyak et al.:** tendencias paralelas para todos los grupos y **todos** los pares de periodos consecutivos.
- **Callaway–Sant’Anna:** más débil. Las cohortes deben ser paralelas a las nunca tratadas solo **desde la adopción**; pueden diferir antes.

La diferencia clave: el periodo base

Un grupo tratado g que adopta en t_s , comparado con el grupo nunca tratado ∞ ; efecto en $t \geq t_s$:

Callaway–Sant’Anna: $(Y_{g,t} - Y_{g,t_s-1}) - (Y_{\infty,t} - Y_{\infty,t_s-1})$

Borusyak et al.: $(Y_{g,t} - \frac{1}{t_s-1} \sum_{t' < t_s} Y_{g,t'}) - (Y_{\infty,t} - \frac{1}{t_s-1} \sum_{t' < t_s} Y_{\infty,t'})$

- CS usa solo el último periodo pre-tratamiento; BJS promedia **todos** los periodos pre-tratamiento.
- $\Rightarrow$ BJS suele ser **más preciso**...
- ...pero **más sesgado** si las tendencias no son exactamente paralelas y la discrepancia crece con el horizonte (p.ej., tendencias lineales por grupo): la base está más lejos en el tiempo.

3. Pruebas placebo

- Con Callaway–Sant’Anna se pueden construir placebos que imitan exactamente al estimador real.
- Con Borusyak et al., al usar todos los periodos previos, es más difícil construir placebos comparables.

¿**Cuál usar?** Depende de:

- qué tan creíble es el supuesto de tendencias paralelas, y qué tipo de violación se espera;
- si la fecha de tratamiento puede redefinirse como la de **anuncio** (anticipación);
- si se planea hacer análisis de sensibilidad.

Regla útil: si estimadores robustos dan resultados muy distintos, el supuesto de tendencias paralelas **debe** estar violado.

Tratamientos no binarios
o no escalonados

Más allá del caso binario y escalonado

de Chaisemartin y D'Haultfœuille (2023)

- De 26 artículos muy citados revisados, solo **4** tienen tratamiento binario y escalonado.
- Diseños comunes: tratamientos que se encienden y apagan, discretos o continuos.

Más allá del caso binario y escalonado

de Chaisemartin y D'Haultfœuille (2023)

- De 26 artículos muy citados revisados, solo **4** tienen tratamiento binario y escalonado.
- Diseños comunes: tratamientos que se encienden y apagan, discretos o continuos.
- de Chaisemartin y D'Haultfœuille (2024) definen el **evento** como el **primer cambio** en el tratamiento del grupo, en F_g .
- Parámetro: efecto de haber cambiado el tratamiento vs. el **status quo**

$$\delta_{g,\ell} = \mathbb{E}[Y_{g,F_g+\ell} - Y_{g,F_g+\ell}(D_{g,1}, \dots, D_{g,1})]$$

i.e., resultado observado vs. resultado si el tratamiento se hubiera quedado en su nivel del periodo 1.

Ejemplo: el parámetro $\delta_{g,\ell}$

Tratamiento no binario: tasa de impuesto (%) en el estado g

Periodo t	1	2	3	4	5	6
Tratamiento observado $D_{g,t}$	7	7	7	9	9	8
Status quo $D_{g,1}$	7	7	7	7	7	7

- Primer cambio en $t = 4 \Rightarrow F_g = 4$. Escribimos $Y_{g,t}(d_1, \dots, d_t)$: resultado potencial dada la **trayectoria** de tratamiento.

Ejemplo: el parámetro $\delta_{g,\ell}$

Tratamiento no binario: tasa de impuesto (%) en el estado g

Periodo t	1	2	3	4	5	6
Tratamiento observado $D_{g,t}$	7	7	7	9	9	8
Status quo $D_{g,1}$	7	7	7	7	7	7

- Primer cambio en $t = 4 \Rightarrow F_g = 4$. Escribimos $Y_{g,t}(d_1, \dots, d_t)$: resultado potencial dada la **trayectoria** de tratamiento.
- $\ell = 0$ (periodo del cambio):

$$\delta_{g,0} = \mathbb{E}[Y_{g,4}(7, 7, 7, 9) - Y_{g,4}(7, 7, 7, 7)]$$

Ejemplo: el parámetro $\delta_{g,\ell}$

Tratamiento no binario: tasa de impuesto (%) en el estado g

Periodo t	1	2	3	4	5	6
Tratamiento observado $D_{g,t}$	7	7	7	9	9	8
Status quo $D_{g,1}$	7	7	7	7	7	7

- Primer cambio en $t = 4 \Rightarrow F_g = 4$. Escribimos $Y_{g,t}(d_1, \dots, d_t)$: resultado potencial dada la **trayectoria** de tratamiento.
- $\ell = 0$ (periodo del cambio):

$$\delta_{g,0} = \mathbb{E}[Y_{g,4}(7, 7, 7, 9) - Y_{g,4}(7, 7, 7, 7)]$$

- $\ell = 2$ (dos periodos después):

$$\delta_{g,2} = \mathbb{E}[Y_{g,6}(7, 7, 7, 9, 9, 8) - Y_{g,6}(7, 7, 7, 7, 7, 7)]$$

captura el efecto de **toda la trayectoria** (subida a 9 y bajada a 8), no de una sola dosis.

Ejemplo: el parámetro $\delta_{g,\ell}$

Tratamiento no binario: tasa de impuesto (%) en el estado g

Periodo t	1	2	3	4	5	6
Tratamiento observado $D_{g,t}$	7	7	7	9	9	8
Status quo $D_{g,1}$	7	7	7	7	7	7

- Primer cambio en $t = 4 \Rightarrow F_g = 4$. Escribimos $Y_{g,t}(d_1, \dots, d_t)$: resultado potencial dada la **trayectoria** de tratamiento.
- $\ell = 0$ (periodo del cambio):

$$\delta_{g,0} = \mathbb{E}[Y_{g,4}(7, 7, 7, 9) - Y_{g,4}(7, 7, 7, 7)]$$

- $\ell = 2$ (dos periodos después):

$$\delta_{g,2} = \mathbb{E}[Y_{g,6}(7, 7, 7, 9, 9, 8) - Y_{g,6}(7, 7, 7, 7, 7, 7)]$$

captura el efecto de **toda la trayectoria** (subida a 9 y bajada a 8), no de una sola dosis.

- **Controles** para $\delta_{g,2}$: estados con tasa de 7% en $t = 1$ que **no la cambian** hasta $t = 6$.

El estimador $DID_{g,\ell}$

$$DID_{g,\ell} = (Y_{g,F_g+\ell} - Y_{g,F_g-1}) - \frac{1}{N_{g,\ell}} \sum_{g' \in \mathcal{C}_{g,\ell}} (Y_{g',F_g+\ell} - Y_{g',F_g-1})$$

- $\mathcal{C}_{g,\ell}$: grupos de control que
 - tienen el **mismo tratamiento en el periodo 1** que g , y
 - **no han cambiado** su tratamiento hasta $F_g + \ell$.

El estimador $DID_{g,\ell}$

$$DID_{g,\ell} = (Y_{g,F_g+\ell} - Y_{g,F_g-1}) - \frac{1}{N_{g,\ell}} \sum_{g' \in \mathcal{C}_{g,\ell}} (Y_{g',F_g+\ell} - Y_{g',F_g-1})$$

- $\mathcal{C}_{g,\ell}$: grupos de control que
 - tienen el **mismo tratamiento en el periodo 1** que g , y
 - **no han cambiado** su tratamiento hasta $F_g + \ell$.
- Requiere tendencias paralelas, evaluables con **placebos**: comparar *switchers* y *non-switchers* antes del cambio.
- Con tratamiento binario y escalonado, sin covariables, coincide con **Callaway–Sant’Anna con controles aún no tratados**.

Agregación e interpretación

- Los $DID_{g,\ell}$ se agregan en DID_ℓ : efecto de haber recibido una cantidad (débilmente) **mayor** de tratamiento durante ℓ periodos.
- **Problema:** DID_ℓ no dice el efecto **por unidad** de tratamiento si los cambios difieren entre grupos.

Agregación e interpretación

- Los $DID_{g,\ell}$ se agregan en DID_ℓ : efecto de haber recibido una cantidad (débilmente) **mayor** de tratamiento durante ℓ periodos.
- **Problema:** DID_ℓ no dice el efecto **por unidad** de tratamiento si los cambios difieren entre grupos.
- **Soluciones:**
 - ① **Primera etapa:** aplicar el mismo estimador a D en lugar de Y y graficar ambos.
 - DID_ℓ^D = cambio promedio del tratamiento vs. status quo a horizonte ℓ . Misma lógica que en IV: la forma reducida sola no se interpreta.

Agregación e interpretación

- Los $DID_{g,\ell}$ se agregan en DID_ℓ : efecto de haber recibido una cantidad (débilmente) **mayor** de tratamiento durante ℓ periodos.
- **Problema:** DID_ℓ no dice el efecto **por unidad** de tratamiento si los cambios difieren entre grupos.
- **Soluciones:**
 - 1 **Primera etapa:** aplicar el mismo estimador a D en lugar de Y y graficar ambos.
 - DID_ℓ^D = cambio promedio del tratamiento vs. status quo a horizonte ℓ . Misma lógica que en IV: la forma reducida sola no se interpreta.
 - 2 **Efecto total promedio por unidad de tratamiento:**

$$\delta = \frac{\sum_g \sum_\ell w_g \delta_{g,\ell}}{\sum_g \sum_\ell w_g (D_{g,F_g+\ell} - D_{g,1})} \quad \text{Ej. (tasa } 7 \rightarrow 9, 9, 8): \frac{0.4 + 0.6 + 0.5}{2 + 2 + 1} = 0.3$$

- Efecto total de la trayectoria observada / unidades de tratamiento (por periodo) recibidas por encima del status quo.
- Útil para **costo–beneficio**: política observada vs. status quo.

- Borusyak, K. (2025). *A Modern Perspective on Difference-in-Differences Designs*. Lecture Notes, UC Berkeley.
- Borusyak, K., Jaravel, X., & Spiess, J. (2024). Revisiting event-study designs: Robust and efficient estimation. *Review of Economic Studies*, 91(6), 3253–3285.
- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- de Chaisemartin, C., & D'Haultfœuille, X. (2023). Two-way fixed effects and differences-in-differences with heterogeneous treatment effects: A survey. *The Econometrics Journal*, 26(3), C1–C30.
- de Chaisemartin, C., & D'Haultfœuille, X. (2024). Difference-in-differences estimators of intertemporal treatment effects. *Review of Economics and Statistics*.
- Gardner, J. (2021). Two-stage differences in differences. Working paper.
- Liu, L., Wang, Y., & Xu, Y. (2024). A practical guide to counterfactual estimators for causal inference with time-series cross-sectional data. *American Journal of Political Science*, 68(1), 160–176.
- Rambachan, A., & Roth, J. (2023). A more credible approach to parallel trends. *Review of Economic Studies*, 90(5), 2555–2591.
- Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175–199.