

# Variables Instrumentales

## Econometría Aplicada y Ciencia de Datos

- 1 Repaso MCO
- 2 Motivación - Variables Instrumentales
- 3 Definición de Instrumento
- 4 Estimador de Variables Instrumentales
- 5 Lenguaje de Variables Instrumentales
- 6 2SLS
- 7 Propiedades 2SLS
- 8 Aplicación: Card (1995)
- 9 Aplicación: Oferta y Demanda

# Repaso MCO

# Repaso: Mínimos Cuadrados Ordinarios (MCO)

Modelo lineal poblacional:  $y = \beta_0 + \beta_1 x_1 + \dots + \beta_K x_K + u$

$$\hat{\beta}_{OLS} = (X'X)^{-1}X'Y$$

## Insesgadez:

- Linealidad en los parámetros
- Muestra aleatoria
- No colinealidad perfecta
- Media condicional cero:  
 $E(u | x_1, \dots, x_K) = 0$

$$\hookrightarrow E(\hat{\beta}_{OLS}) = \beta$$

## Consistencia:

- Muestra aleatoria
- No colinealidad perfecta
- Ortogonalidad:  
 $E(u) = 0, \text{Cov}(x_j, u) = 0 \quad \forall j$

$$\hookrightarrow \hat{\beta}_{OLS} \xrightarrow{p} \beta$$

- $E(u | x) = 0 \Rightarrow \text{Cov}(x_j, u) = 0 \quad \forall j$ , pero **no** al revés: insesgadez es *más fuerte* que consistencia.
- Insesgadez + homoced. ( $\text{Var}(u | x_1, \dots, x_K) = \sigma^2$ )  $\Rightarrow$  Gauss–Markov:  $\hat{\beta}_{OLS}$  BLUE

## Repaso: Insesgadez de MCO

$$y = X\beta + u, \quad \hat{\beta} = (X'X)^{-1}X'y$$

**Supuestos:** linealidad, muestra aleatoria, no colinealidad perfecta ( $X'X$  invertible), y  $E(u | X) = 0$

**Paso 1 — Sustituir el modelo verdadero:**

$$\hat{\beta} = (X'X)^{-1}X'(X\beta + u) = (X'X)^{-1}X'X\beta + (X'X)^{-1}X'u$$

**Paso 2 — Simplificar:**  $(X'X)^{-1}X'X = I$ ,

$$\hat{\beta} = \beta + (X'X)^{-1}X'u$$

**Paso 3 — Esperanza condicional en  $X$ :**

$$E(\hat{\beta} | X) = \beta + (X'X)^{-1}X' E(u | X) = \beta + (X'X)^{-1}X' \cdot 0 = \beta$$

**Paso 4 — Ley de esperanzas iteradas:**

$$E(\hat{\beta}) = E[E(\hat{\beta} | X)] = E(\beta) = \beta$$

## Repaso: Consistencia de MCO

$$\hat{\beta} = \beta + (X'X)^{-1}X'u = \beta + \left(\frac{1}{N}X'X\right)^{-1}\left(\frac{1}{N}X'u\right)$$

**Supuestos:** muestra aleatoria i.i.d.,  $E(u) = 0$ ,  $\text{Cov}(x_j, u) = 0 \forall j$ , y  $E(x'x)$  finita y no singular.

**Paso 1 — Ley de Grandes Números (LGN) aplicada a  $N^{-1}X'X$ :**

$$\frac{1}{N}X'X = \frac{1}{N} \sum_{i=1}^N x'_i x_i \xrightarrow{p} E(x'x)$$

**Paso 2 — LGN aplicada a  $N^{-1}X'u$ :**

$$\frac{1}{N}X'u = \frac{1}{N} \sum_{i=1}^N x'_i u_i \xrightarrow{p} E(x'u) = 0$$

**Paso 3 — Teorema de Slutsky** (funciones continuas preservan la convergencia en probabilidad):

$$\text{plim } \hat{\beta} = \beta + [E(x'x)]^{-1} \cdot 0 = \beta$$

# Model and Estimator

**With normality:**

$$y = X\beta + u, \quad u \mid X \sim (0, \sigma^2 I_n)$$

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} \mid X \sim N(\beta, \sigma^2(X'X)^{-1})$$

**Without normality:** asymptotically (CLT)

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \sigma^2 Q^{-1}), \quad Q = \text{plim } \frac{1}{n}X'X$$

Feasible variance estimate:

$$\widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1}, \quad \hat{\sigma}^2 = \frac{\hat{u}'\hat{u}}{n - k}$$

## $t$ -test: Single Coefficient

Test:  $H_0 : \beta_j = \beta^*$  vs.  $H_1 : \beta_j \neq \beta^*$

$$t_j = \frac{\hat{\beta}_j - \beta^*}{\text{se}(\hat{\beta}_j)} \sim t_{n-k} \quad \text{under } H_0$$

- **Reject  $H_0$**  at level  $\alpha$  if  $|t_j| > t_{n-k, \alpha/2}$ .
- $(1 - \alpha)$  confidence interval:  $\hat{\beta}_j \pm t_{n-k, \alpha/2} \cdot \text{se}(\hat{\beta}_j)$
- As  $n - k \rightarrow \infty$ :  $t_{n-k} \rightarrow N(0, 1)$ .



# F-test: Joint Restrictions

1. Test  $q$  linear restrictions  $H_0 : R\beta = r$ :

$$F = \frac{(\text{RSS}_R - \text{RSS}_{UR})/q}{\text{RSS}_{UR}/(n-k)} \sim F_{q, n-k} \quad \text{under } H_0$$

- Reject  $H_0$  if  $F > F_{q, n-k, \alpha}$ .

2. **Overall significance** ( $H_0 : \beta_1 = \cdots = \beta_{k-1} = 0$ ):

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{k-1, n-k}$$

- Reject  $H_0$  if  $F > F_{k-1, n-k, \alpha}$ .


## Motivación - Variables Instrumentales

# Motivación: ¿Por qué necesitamos Variables Instrumentales?

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_K x_K + u$$


- Cuando  $\text{Cov}(x_j, u) = 0$  falla: MCO es **sesgado e inconsistente**.
- Fuentes de endogeneidad:
  - Variables omitidas (p. ej., habilidad no observada)
  - Error de medición en los regresores
  - Simultaneidad / causalidad inversa

## Sin endogeneidad



$x$  y  $u$  son causas independientes de  $y$ : MCO consistente.

## Regresor endógeno



$u$  afecta tanto a  $x$  como a  $y$ : MCO captura un efecto *directo + indirecto*  $\Rightarrow$  sesgo.

- **Variables Instrumentales:** explotar una fuente externa de variación *exógena* en el regresor endógeno.

## Definición de Instrumento

Consideremos el modelo

$$y = \beta_0 + \beta_1 x + u, \quad \text{cov}(x, u) \neq 0$$

Una variable  $z_1$  es un **instrumento válido**:

## 1. Exogeneidad

$z$  no está correlacionada con el error:

$$\text{cov}(z, u) = 0$$

## 2. Relevancia

$z$  está correlacionada con el regresor endógeno:

$$\text{cov}(z, x) \neq 0$$

# Estimador de Variables Instrumentales

Tomando la covarianza con  $z$  en ambos lados de  $y = \beta_0 + \beta_1 x + u$ :

$$\text{cov}(y, z) = \beta_1 \text{cov}(x, z) + \text{cov}(u, z)$$

Como  $\text{cov}(u, z) = 0$  por exogeneidad, despejamos:

$$\hat{\beta}_1 = \frac{\text{cov}(y, z)}{\text{cov}(x, z)}, \quad \text{siempre que } \text{cov}(x, z) \neq 0$$

- Por una Ley de Grandes Números:

$$\widehat{\text{cov}}(x, z) \xrightarrow{P} \text{cov}(x, z) \neq 0 \quad (\text{relevancia}), \quad \widehat{\text{cov}}(u, z) \xrightarrow{P} \text{cov}(u, z) = 0 \quad (\text{exogeneidad})$$

$\hat{\beta}_1$  es **consistente**

- Sin embargo,  $\hat{\beta}_1$  es **siempre sesgado** en muestras finitas.
- El sesgo puede ser sustancial si la muestra es pequeña  $\Rightarrow$  tener precaución con el tamaño muestral.

# Estimador de VI

Modelo:  $y = \beta x + u$ , instrumento  $z$ .

## Derivación intuitiva (Heckman)

$$\beta_{VI} = \frac{dy/dz}{dx/dz}$$

Se estiman  $dy/dz$  y  $dx/dz$  mediante pendientes simples de MCO:

$$\hat{\beta}_{VI} = \frac{(z'z)^{-1}z'y}{(z'z)^{-1}z'x} = (z'x)^{-1}z'y$$

## Forma de covarianza

$$\hat{\beta}_{VI} = \frac{\text{Cov}[z, y]}{\text{Cov}[z, x]} = \frac{r_{zy}}{r_{zx}} \sqrt{\frac{y'y}{x'x}}$$



## Ejemplo: Rendimientos a la Educación

- Card (1995) estudia los **retornos a la educación** - muestra 5,525 hombres 14-24 años.
- Interesa la relación entre educación e ingreso, pero la habilidad no se observa:  
estimar  $\ln(w_i) = \beta_0 + \beta_1 educ_i + u_i$  produce un  $\hat{\beta}_1$  sesgado.
- **Instrumento propuesto:** una variable binaria que indica si en el municipio de la persona  $i$  había una universidad cercana.
- **Intuición:** la cercanía de la universidad reduce el costo de asistir, pero no afecta directamente el ingreso (solo a través de la escolaridad).

Encontrar un buen instrumento casi nunca es sencillo: exige entender los mecanismos, las instituciones y el contexto detrás de la variable endógena.

# Lenguaje de Variables Instrumentales

## Ecuación estructural:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_K x_K + u, \quad \text{Cov}(x_K, u) \neq 0$$

- $x_K$ : variable endógena
- $z_1$ : instrumento válido

## Forma reducida:

$$x_K = \delta_0 + \delta_1 x_1 + \cdots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + r_K \text{ (forma reducida de } x_K \text{)}$$

Sustituyendo en la ecuación estructural se obtiene la forma reducida de  $y$ :

$$y = \alpha_0 + \alpha_1 x_1 + \cdots + \alpha_{K-1} x_{K-1} + \lambda_1 z_1 + v, \quad v = u + \beta_K r_K \text{ (forma reducida de } y \text{)}$$

$$\text{con } \alpha_j = \beta_j + \beta_K \delta_j \text{ y } \lambda_1 = \beta_K \theta_1$$

- MCO estima de forma consistente los parámetros de la forma reducida  $\alpha_j, \lambda_1$ .
- Las estimaciones de forma reducida a veces interesan por sí mismas, pero el parámetro estructural  $\beta_K$  suele ser el de interés.

La **primera etapa** especifica la relación entre la variable endógena y el instrumento:

$$x_K = \delta_0 + \delta_1 x_1 + \cdots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + r_K$$

- La condición de relevancia se reescribe como  $\theta_1 \neq 0$ .
- La primera etapa **puede y debe** probarse empíricamente.

## Restricción de exclusión

No es posible probar directamente que  $\text{cov}(z_i, u_i) = 0$ . Esta restricción debe sustentarse en la teoría económica, el conocimiento institucional, o la exogeneidad de un experimento natural.

# Más de un Instrumento

- Si existen  $J$  variables  $z_{ij}$  candidatas a instrumento: cada una debe cumplir  $\text{cov}(u_i, z_{ij}) = 0$  y correlacionarse con  $x_{1i}$ .

Ejemplo: dos instrumentos, la primera etapa es

$$x_K = \delta_0 + \delta_1 x_1 + \cdots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + \theta_2 z_2 + r_K$$

con  $\text{cov}(z_1, r_K) = \text{cov}(z_2, r_K) = \text{cov}(x_j, r_K) = 0, \forall j \neq K$ .

- Para lograr identificación, basta con  $\theta_1 \neq 0$  o  $\theta_2 \neq 0$ .
- Puede usarse una prueba  $F$  para contrastar  $H_0 : \theta_1 = \theta_2 = 0$ .

**Exactamente identificado:** número de instrumentos = número de variables endógenas

**Sobreidentificado:** número de instrumentos  $>$  número de variables endógenas

2SLS

# Mínimos Cuadrados en Dos Etapas

El procedimiento para estimar  $\beta_1$  en dos pasos:

- 1 Regresión de  $x_{1i}$  sobre los instrumentos y las variables exógenas  $\Rightarrow$  valores ajustados  $\hat{x}_{1i}$ .

$$x_K \text{ sobre } 1, x_1, \dots, x_{K-1}, z_1, \dots, z_M$$

- 2 Regresión de  $y_i$  sobre las variables exógenas y  $\hat{x}_{1i}$ .

$$y \text{ sobre } 1, x_1, \dots, x_{K-1}, \hat{x}_K$$

Es como *purgar* a  $x_{1i}$  de su correlación con  $u_i$ .

## Advertencia

- Nunca omita los regresores exógenos  $x_1, \dots, x_{K-1}$  en la regresión de primera etapa (produce estimadores inconsistentes)
- Nunca se hace este procedimiento “a mano” — los errores estándar de la segunda etapa serían incorrectos.

## Propiedades 2SLS



# Supuestos Generales para 2SLS (Wooldridge)

## Supuesto 2SLS.1 (Ortogonalidad $\approx$ Exogeneidad)

Para el vector  $1 \times L$   $z$ :  $E(z'u) = 0$ .

## Supuesto 2SLS.2 (Condiciones de rango $\approx$ Relevancia)

(a)  $\text{rank } E(z'z) = L$     (b)  $\text{rank } E(z'x) = K$

## Supuesto 2SLS.3 (Homocedasticidad)

$$E(u^2 z'z) = \sigma^2 E(z'z), \quad \sigma^2 = E(u^2)$$

Condición de orden:  $L \geq K$

- ❶ Bajo 2SLS.1–2SLS.2: el estimador 2SLS obtenido de una muestra aleatoria es **consistente** para  $\beta$ :

$$\hat{\beta} \xrightarrow{p} \beta$$

- ❷ Bajo 2SLS.1–2SLS.3:

$$\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}\left(0, \sigma^2 \left( [E(x'z)] [E(z'z)]^{-1} [E(z'x)] \right)^{-1}\right)$$

- Matriz de varianza estimada:  $\hat{\sigma}^2(\hat{X}'\hat{X})^{-1}$ , con  $\hat{\sigma}^2 = (N - K)^{-1} \sum_i \hat{u}_i^2$  usando los residuos *estructurales* de 2SLS  $\hat{u}_i = y_i - x_i\hat{\beta}$  (**no** los residuos de MCO de la segunda etapa).
- ❸ Bajo 2SLS.1–2SLS.3: 2SLS es **eficiente** dentro de la clase de todos los estimadores de VI que usan instrumentos lineales en  $z$ .
- Si  $x$  es exógena, 2SLS = MCO
  - Si falla el Supuesto 2SLS.3, existe un estimador GMM más eficiente (Hansen 1982; White 1982)

Aplicación: Card (1995)

## Ejemplo Card (1995): Rendimientos a la Educación

En el problema de Card (1995), la primera etapa es

$$esc_i = \pi_0 + \pi_1 X_i + \phi unicerca_i + \nu_i, \quad unicerca_i = \begin{cases} 1 & \text{había universidad en el municipio} \\ 0 & \text{en otro caso} \end{cases}$$

Y la forma reducida es

$$\ln(w_i) = \gamma_0 + \gamma_1 X_i + \delta unicerca_i + \varepsilon_i$$

El salario está correlacionado con la presencia de la universidad, pero esa relación ocurre **a través de la escolaridad**.

# Ejemplo Card (1995): Estimación en R

Datos de Card, variable instrumental `nearc4` (universidad cercana):

R

```
library(readr)
card <- read_csv(
  "your folder address/card1995.csv"
)

# OLS
ols_formula <- lwage ~ educ + exper + black + south + married + smsa
ols_fit <- lm(ols_formula, data = card)

print(summary(ols_fit))

# Variables instrumentales
iv_formula <- lwage ~ educ + exper + black + south + married + smsa |
  nearc4 + exper + black + south + married + smsa
iv_fit <- ivreg(iv_formula, data = card)

print(summary(iv_fit))
```

## Ejemplo Card (1995): MCO vs. VI

El  $\hat{\beta}_1$  de MCO es inconsistente; comparamos con la estimación de VI:

|       | MCO              | VI               |
|-------|------------------|------------------|
| educ  | 0.071<br>(0.003) | 0.124<br>(0.050) |
| exper | 0.034<br>(0.002) | 0.056<br>(0.020) |
| N     | 3,003            | 3,003            |
| F     | 219.15           | —                |

El coeficiente de VI (0.124) es notablemente mayor que el de MCO (0.071), con un error estándar bastante más grande — patrón típico cuando el instrumento no es muy fuerte.

## Ejemplo Card (1995): Primera Etapa

|        | MCO              | VI               | Primera etapa     |
|--------|------------------|------------------|-------------------|
| educ   | 0.071<br>(0.003) | 0.124<br>(0.050) |                   |
| exper  | 0.034<br>(0.002) | 0.056<br>(0.020) | -0.404<br>(0.009) |
| nearc4 |                  |                  | 0.327<br>(0.082)  |
| N      | 3,003            | 3,003            | 3,003             |
| F      | 219.15           | —                | 456.14            |

El coeficiente de `nearc4` en la primera etapa (0.327) es positivo y significativo: la cercanía a una universidad aumenta la escolaridad esperada.

## Ejemplo Card (1995): Fuerza del Instrumento

Debe verificarse el estadístico  $F$  de la primera etapa asociado *solo* a los instrumentos excluidos:

R

```
pe_vi <- lm(educ ~ nearc4 + exper + black + south + married + smsa,  
            data = data.ingresos)  
  
linearHypothesis(pe_vi, c("nearc4 = 0"))
```

| Modelo      | Res. Df | RSS    | F     | Pr(>F)               |
|-------------|---------|--------|-------|----------------------|
| Restringido | 2,997   | 11,304 |       |                      |
| Completo    | 2,996   | 11,245 | 15.77 | $7.3 \times 10^{-5}$ |

$F \approx 15.8$  para un único instrumento: por encima de la regla práctica de  $F > 10$ , aunque no de forma holgada.



## Aplicación: Oferta y Demanda

# Ejemplo Oferta y Demanda

Supongamos que interesa estimar la elasticidad de la demanda de mantequilla:

$$\ln(q_i) = \alpha + \beta \ln(p_i) + \varepsilon_i$$

con datos de precio y consumo para una muestra grande de localidades  $i$ .

## El problema de simultaneidad

Si estimamos esta ecuación por MCO,  $\hat{\beta}$  es **inconsistente**: precio y cantidad se determinan simultáneamente en el equilibrio de oferta y demanda. Un choque a cualquiera de las dos curvas mueve ambas variables a la vez.

# Ejemplo Oferta y Demanda: la Solución de VI

Para estimar la elasticidad de la **demanda** necesitamos una variable  $z$  que:

- afecte solo a la **oferta** (p. ej., precipitación o temperatura, que inciden en la producción);
- no afecte directamente a la demanda.

**Intuición gráfica:** al desplazar la curva de oferta mientras la demanda permanece fija, los distintos puntos de equilibrio observados *trazan* la curva de demanda, permitiendo identificar y estimar su elasticidad.

# Ejemplo Oferta y Demanda: Identificación Gráfica en R

Para ilustrar la intuición, simulamos una demanda fija y tres curvas de oferta desplazadas por un instrumento (p. ej., condiciones climáticas):

R


```
p <- seq(1, 9, by = 0.1)

demanda <- 10 - p # curva de demanda fija
oferta_1 <- p - 1 # oferta con clima promedio
oferta_2 <- p - 3 # oferta con clima favorable (mas produccion)
oferta_3 <- p - 5 # oferta con clima muy favorable

plot(demanda, p, type = "l", col = "blue", lwd = 2,
      xlab = "Cantidad", ylab = "Precio", xlim = c(0, 9))
lines(oferta_1, p, col = "red")
lines(oferta_2, p, col = "red", lty = 2)
lines(oferta_3, p, col = "red", lty = 3)
```

Cada desplazamiento de la oferta genera un nuevo punto de equilibrio observado (precio, cantidad); estos puntos son los que usamos para estimar la curva de demanda.

## Ejemplo Oferta y Demanda: Identificación Gráfica



Cada choque exógeno a la oferta ( $S_1 \rightarrow S_2 \rightarrow S_3$ ) genera un nuevo equilibrio observado ( $E_1, E_2, E_3$ ) **sobre la curva de demanda fija**  $D_1$  — así es como VI identifica su pendiente (elasticidad).